


OntiCards 用户手册

企业级智能数据中枢 · 让数据库"听得懂人话"



本手册详细介绍 **OntiCards** 各功能模块的使用方法，覆盖从登录初始化、数据源接入、智能问数、数据治理到系统管理的全流程操作，帮助业务人员、数据分析师、数据治理专员和管理者快速上手并用好这套 AI 数据中枢。

目录

- [一、产品概述](#)
 - [1.1 产品定位](#)
 - [1.2 核心能力](#)
 - [1.3 适用人群](#)
 - [1.4 主导航结构](#)
- [二、登录与初始化](#)
 - [2.1 登录方式](#)
 - [2.2 概览首页](#)
 - [2.3 首次使用流程](#)
- [三、工作空间（数据源管理）](#)

- 3.1 工作空间总览
- 3.2 添加数据源
- 3.3 支持的数据库类型
- 3.4 刷新数据源
- 3.5 删除数据源
- 四、数据源详情
 - 4.1 概览
 - 4.2 库表
 - 4.3 卡片（数据卡片）
 - 4.4 增强（字段注释增强）
 - 4.5 问数（智能问数）
 - 4.6 知识（业务术语库）
 - 4.7 历史（历史查询）
 - 4.8 任务（数据盘点）
- 五、智能问数（自然语言查询）
 - 5.1 基本查询
 - 5.2 多步推理查询
 - 5.3 跨源融合查询
 - 5.4 查询结果解读
 - 5.5 优化查询结果
- 六、业务术语库
 - 6.1 什么是业务术语库
 - 6.2 创建术语库
 - 6.3 在数据源中关联术语库
- 七、数据盘点
 - 7.1 全域盘点
 - 7.2 定向盘点
 - 7.3 盘点结果管理
- 八、字段注释增强
 - 8.1 准备 Excel 字典文件
 - 8.2 上传与配置
 - 8.3 查看增强结果
- 九、数据质检
 - 9.1 规则库管理
 - 9.2 创建质检规则
 - 9.3 执行质检
 - 9.4 质量评分

- 9.5 质检报告
 - 十、监控中心
 - 10.1 监控总览
 - 10.2 趋势分析
 - 10.3 实时监控
 - 10.4 性能分析
 - 十一、成本管理
 - 11.1 Token 价格配置
 - 11.2 成本统计
 - 十二、系统与账户
 - 12.1 账户信息
 - 12.2 用户管理
 - 12.3 API 密钥
 - 12.4 模型配置
 - 12.5 数据保密
 - 12.6 鉴权日志
 - 12.7 系统设置
 - 十三、数据安全
 - 十四、API 与第三方集成
 - 十五、SSO 单点登录对接 (JWT 模式)
 - 15.1 什么是 JWT Token
 - 15.2 整体流程
 - 15.3 配置清单
 - 15.4 Token 生成详解
 - 15.5 各语言示例
 - 15.6 拼接登录 URL 并跳转
 - 15.7 回调接收 Token
 - 15.8 错误码说明
 - 15.9 测试验证
 - 十六、常见问题 (FAQ)
 - 十七、获取帮助
-

一、产品概述

1.1 产品定位

OntiCards 是面向企业的 **AI 数据中枢**（AI Data Hub），围绕业务数据库提供一站式能力：

📌 让企业数据库从「只有会写 SQL 才能使用」变成 **懂业务语言就可以查询、质检、管理、审计数据**。

与传统 BI 工具不同，OntiCards 以 **AI 驱动的自然语言交互** 为核心，让业务团队真正"自助"用数据；又与传统 NL2SQL 玩具不同，OntiCards 把 **数据接入 → 元数据理解 → 智能问数 → 数据治理 → 平台管理** 串成一条完整的闭环。

1.2 核心能力

能力	说明
🏠 多源数据接入	支持 MySQL、PostgreSQL、Oracle、达梦、人大金仓、OceanBase、SQL Server、Trino、SQLite 等
🧠 智能数据理解	自动生成数据卡片、字段画像、业务术语库、AI 表关系盘点
🔍 自然语言查询	NL2SQL 引擎，多步推理，多数据库方言适配，业务术语自动展开，安全校验
🔗 跨源融合查询	一次提问同时查询多个数据源，自动对齐结果，打破数据孤岛
✅ 数据质检平台	多种质检规则、质量评分、自动化质检报告
🏢 企业级平台能力	数据源隔离、敏感脱敏、操作审计、API-Key、JWT-SSO、查询监控与成本统计
🤖 第三方集成	通过 API-Key 对接智能体、RPA、BI 平台、自研系统

1.3 适用人群

角色	使用场景	获得价值
业务运营人员	日常数据监控、异常排查	自助查询，无需等待数据团队
数据分析师	验证假设、临时查询、跨库整合	节省写 SQL 时间，专注分析工作
数据治理专员	规则库配置、质检执行、术语统一	系统化提升数据质量
管理层	多数据源汇总对比、决策支持	获得全局视图，快速决策
IT / 数据团队	数据源管理、权限管控、审计监控	统一管控平台，降低运维成本
业务系统开发者	通过 API 集成智能问数能力	为业务系统注入 AI 问数能力

1.4 主导航结构

登录后左侧主导航包含以下模块：


导航	路径	用途
概览	/overview	数据源全景、使用流程、快捷入口
工作空间	/workspaces	管理所有数据源、进入数据源详情
业务术语	/business-terms	跨数据源共享的业务术语库
数据质检	/governance	规则库、执行、报告
监控中心	/monitoring	实时查询量、Token、性能监控
成本管理	/cost-config	Token 成本与每日成本趋势
系统与账户	/settings	账户、用户、API-Key、模型、保密设置
帮助	/help	文档、FAQ、问题反馈

二、登录与初始化

2.1 登录方式

访问 OntiCards 后将进入登录页面。系统提供以下登录方式：

方式一：用户名密码登录（默认）



- 在用户名输入框填写账户名
- 在密码输入框填写密码（点击眼睛图标可显示明文）
- 点击「登录」按钮

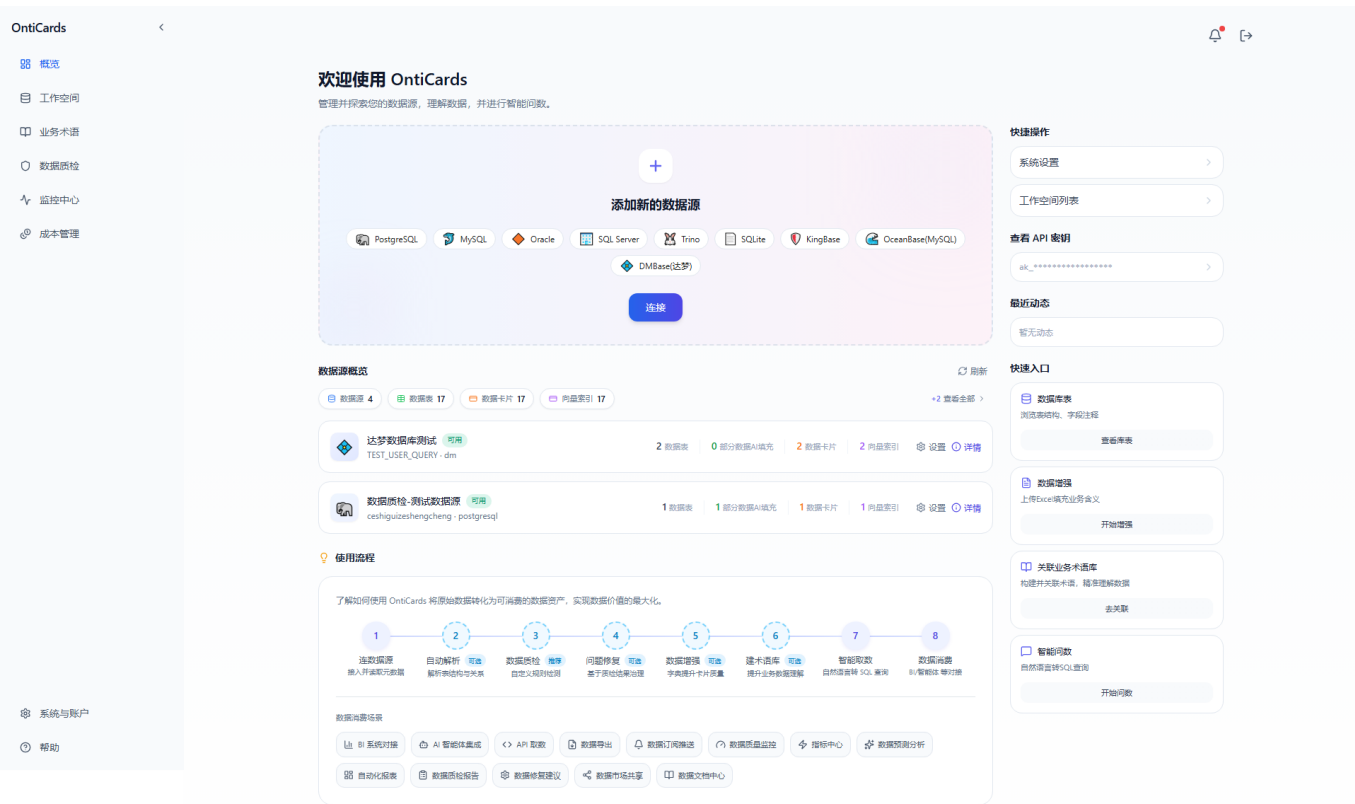
💡 忘记密码请联系系统管理员重置。

方式二：JWT-SSO 单点登录（企业版配置）

支持与企业内部身份系统（通过JWT的方式）打通，使用企业账号一键登录。具体接入请参考 [部署指南 - SSO 配置](#)。

2.2 概览首页

登录成功后默认进入「概览」首页。



首页包含以下区域：

- **添加数据源快捷入口：**提供 8 种主流数据库的连接卡片（PostgreSQL、MySQL、Oracle、SQL Server、Trino、SQLite、KingBase、OceanBase(MySQL)、DMBase(达梦)），点击「连接」按钮直接进入新建数据源流程
- **数据源概览：**顶部展示当前账号下数据源总数、数据表总数、数据卡片总数、向量索引数等核心指标
- **数据源列表：**展示已添加的所有数据源卡片，显示连接状态、数据表数、数据卡片数、最后更新时间
- **使用流程：**以 8 步流程图展示完整使用路径（连数据源 → 自动解析 → 数据增强 → 问题修复 → 数据增强 → 建术语库 → 智能取数 → 数据治理）
- **数据流通场景：**展示 B 系统对接、API 取数、数据导出、数据订阅读取、数据质量监控、指标中心、数据预览等典型场景

- **快捷操作区（右侧）**：系统设置、工作空间列表、查看 API 密钥、最近动态

2.3 首次使用流程

推荐的首次使用流程：




🕒 完成前 4 步（登录、添加数据源、生成卡片、补充术语）通常 30 分钟内即可上手问数。

三、工作空间（数据源管理）

「工作空间」是 OntiCards 中管理所有数据源的中心。

3.1 工作空间总览

进入「工作空间」后看到所有已添加的数据源。



顶部指标卡：

指标	含义
工作空间总数	当前账号下已添加的数据源数量
可用	状态为「可用」的数据源数量
数据表总数	所有数据源下的表/视图总数量
数据卡片	已生成的智能数据卡片数量
向量索引	已建好的向量索引数（用于 NL2SQL 检索）


数据源卡片展示每个数据源的：

- 数据库类型标签（POSTGRESQL、DM、ORACLE 等）
- 名称与英文别名
- 数据库类型图标
- 表数量、卡片数、向量索引数
- 状态（可用 / 异常）
- 最后更新日期
- 操作按钮：刷新、设置、详情

3.2 添加数据源

步骤 1：进入添加表单

在「工作空间」页或「概览」页点击「连接」按钮（位于添加数据源快捷区或右上角），弹出添加数据源对话框。



步骤 2：填写连接信息

字段	说明	示例
数据源名称 *	便于识别的业务名称	电商生产库
数据源类型 *	9 种数据库类型可选	MySQL
用户名 *	拥有 SELECT 权限的账号	readonly_user
密码 *	对应账号的密码	*****
主机地址 *	数据库服务器 IP 或域名	192.168.1.100
端口 *	数据库监听端口	3306
数据库名 *	具体要接入的库	ecommerce

步骤 3：测试连接

点击「测试连接」，系统会验证：

- 网络可达性
- 账号密码正确性
- 目标库存在性

- 必要权限 (SELECT)

测试通过后按钮变为「请先测试连接」可继续点击保存。

步骤 4：保存

点击「请先测试连接」变为「保存」后提交，系统会：

1. 写入数据源元数据
2. 自动拉取所有表与字段信息
3. 自动启动 **数据卡片生成任务**（异步执行）
4. 写入「任务」标签，可在「任务」页查看进度

 **重要：**为安全起见，建议使用 **仅具备 SELECT 权限的只读账号**。OntiCards 不执行任何 DML/DDDL 操作。

3.3 支持的数据库类型

数据库	类型	备注
MySQL	开源	主流数据库，5.7+
PostgreSQL	开源	10+，兼容人大金仓（KingBase）
Oracle	商业	11g+
SQL Server	商业	2012+
Trino	OLAP	大数据查询引擎
SQLite	轻量	测试/小规模
KingBase	国产	电科金仓
OceanBase (MySQL)	国产	蚂蚁分布式数据库（MySQL 租户）
DMBase（达梦）	国产	武汉达梦，V8

3.4 刷新数据源

当数据库结构发生变化（新增表、新增/修改字段）时，需要刷新：

1. 在数据源卡片右上角点击「刷新」图标
2. 系统增量识别变化的表与字段
3. 对新增的表自动启动数据卡片生成
4. 已有的卡片会保留人工编辑结果

💡 智能增量识别：仅重生成有变化的表，避免大库刷新耗时。

3.5 删除数据源

- 1. 在数据源卡片右上角「...」菜单中点击「删除」
- 2. 弹出确认对话框
- 3. 确认后该数据源及其所有数据卡片、历史查询将被清除

⚠️ 删除操作 **不可逆**。如担心误删，可先将数据源标记为「停用」（如有此权限）。

四、数据源详情

点击数据源卡片任意位置，即可进入该数据源的详情页。

详情页包含以下顶部信息和 8 个功能 Tab：


顶部信息：

- 数据源名称、连接状态徽标
- 数据表数、数据卡片数、向量索引数、最后更新时间
- 「设置」按钮：进入数据源配置
- 「执行盘点」按钮：快速启动数据盘点任务

8 个功能 Tab：

Tab	用途
概览	数据源概览、连接信息、表与卡片统计
库表	浏览所有表与字段、查看详情
卡片	浏览/管理智能数据卡片
增强	通过 Excel 上传补充字段注释
问数	自然语言查询入口
知识	该数据源关联的业务术语库
历史	该数据源的历史查询记录
任务	数据盘点任务（定向/全域）


4.1 概览



展示：

- **连接信息**：类型、数据名、Schema、版本
- **表与卡片完成情况**：列出所有表，每张表显示"已生成/未生成"卡片状态
- **表内字段分布**：主键、外键、索引数

4.2 库表



该 Tab 列出该数据源下的所有表与视图：


- **表名**：默认以数据库原名展示
- **类型**：表（TABLE） / 视图（VIEW）
- **字段数**：每张表的字段数量
- **描述**：自动生成的表业务描述
- **状态**：卡片是否已生成（已填充 / 未填充）
- **操作**：查看详情、生成/重新生成数据卡片

点击表名或「查看详情」：

可进入表详情页，浏览：

- 表的完整字段列表（字段名、类型、是否主键、是否可空、默认值、注释）
- 字段与数据卡片的对应关系
- 字段在示例查询中的常见用法

4.3 卡片（数据卡片）



数据卡片是 OntiCards 最重要的元数据资产之一。系统会为每张表自动生成一张"业务说明书"。

卡片列表展示该数据源下所有表的数据卡片，每张卡片显示：

- 数据库类型徽标
- 表名（如 EMP、DEPT）
- 业务描述（自动摘要）
- 关键字段标签
- 字段数与注释数（如 7 字段 / 21 标签）

点击「查看」进入卡片详情：

数据库：POSTGRESQL

字段数：3

主键：code

更新：2026/8/13 18:05:19

描述 (ABSTRACT)

本表为系统基础数据字典表，用于存储国家标准的省、市、区县等各级行政区划代码与名称，为系统提供统一的地区基础数据支持，常被用户表等关联使用。【字段详情】- code(VARCHAR): 区划代码，主键，唯一标识行政区划，示例: 330100, 310000, 440100, 510100, 110000。- name(VARCHAR): 区划名称，对应区划代码的中文标准名称，示例: 广州市, 深圳市, 上海市, 北京市, 杭州市。- level(SMALLINT): 区划层级，标识行政区划的行政级别，枚举值: [1=一级/省级]。【查询场景】- 查询全国或特定级别的行政区划列表 - 根据区划代码反查对应的地区名称 - 关联用户表 (如t_user_test) 统计各省份的用户分布情况 - 获取省级 (level=1) 行政区划数据用于前端下拉框展示

标签 (TAGS)

sys_region

行政区划字典表

地区字典表

省市区配置表

行政区划表

code

区划代码

name

区划名称

level

区划层级

一级/省级

110000

北京市

广州市

深圳市

上海市

杭州市

330100

310000

440100

510100

行政区划

省份

城市

区县

地区编码

国家标准区划

基础数据

字典表

系统配置

查询区划

统计省份

获取地区

有哪些省份

怎么查询区划代码

关联用户省份

区划列表

关键概念 (KEY CONCEPTS)

主题 (CANONICAL TOPIC)

行政区划字典

别名 (ALIAS)

地区字典表

省市区配置表

sys_region

行政区划表

关键实体 (KEY ENTITIES)

行政区划

区划代码

区划名称

一级/省级

省份

城市

区县

适用场景 (APPLICABLE SCENARIOS)

查询行政区划列表

根据代码查地区名称

统计各省用户分布

获取省级区划数据

#	字段名	类型	注释
1	code PK AI	VARCHAR(20)	区划代码，例如: 110000
2	name AI	VARCHAR(100)	区划名称，例如: 北京市
3	level AI	SMALLINT	区划层级，例如: 1

一张完整的数据卡片包含 6 个核心模块，以 sys_region (行政区划字典表) 为例：

模块	内容	实例
ABSTRACT (描述)	表的业务用途说明 + 字段逐项解释 + 查询场景	系统基础数据字典表，用于存储国家标准省/市/区县代码与名称；字段 code 为主键唯一行政区代码，name 为区划名称，level 为区划层级
TAGS (标签)	自动打上的字段标签与业务词	sys_region、行政区划字典表、主键、code、北京市 广州市 上海市 等枚举值

模块	内容	实例
KEY CONCEPTS (关键概念)	表的主题与别名	主题： 行政区划字典 ；别名：地区字典表、省市区配置表、行政区列表
KEY ENTITIES (关键实体)	表涉及的业务实体类型	行政区划、区划代码、区划名称、一级/省级、省份、城市、区县
APPLICABLE SCENARIOS (适用场景)	该表适合回答的业务问题	查询行政区划列表、根据代码查地区名称、统计各省用户分布、获取省区划数据
SQL META (元数据)	字段名、类型、注释的完整列表	其他详情信息底部

关于「LLM 填充」徽标：

- 卡片标题旁的 **LLM 填充** 标识表示该卡片由大模型自动生成
- **人工编辑** 后的卡片会自动取消该徽标，刷新数据源时不会被覆盖
- 「JSON」标签可查看卡片结构化数据，便于与外部系统对接

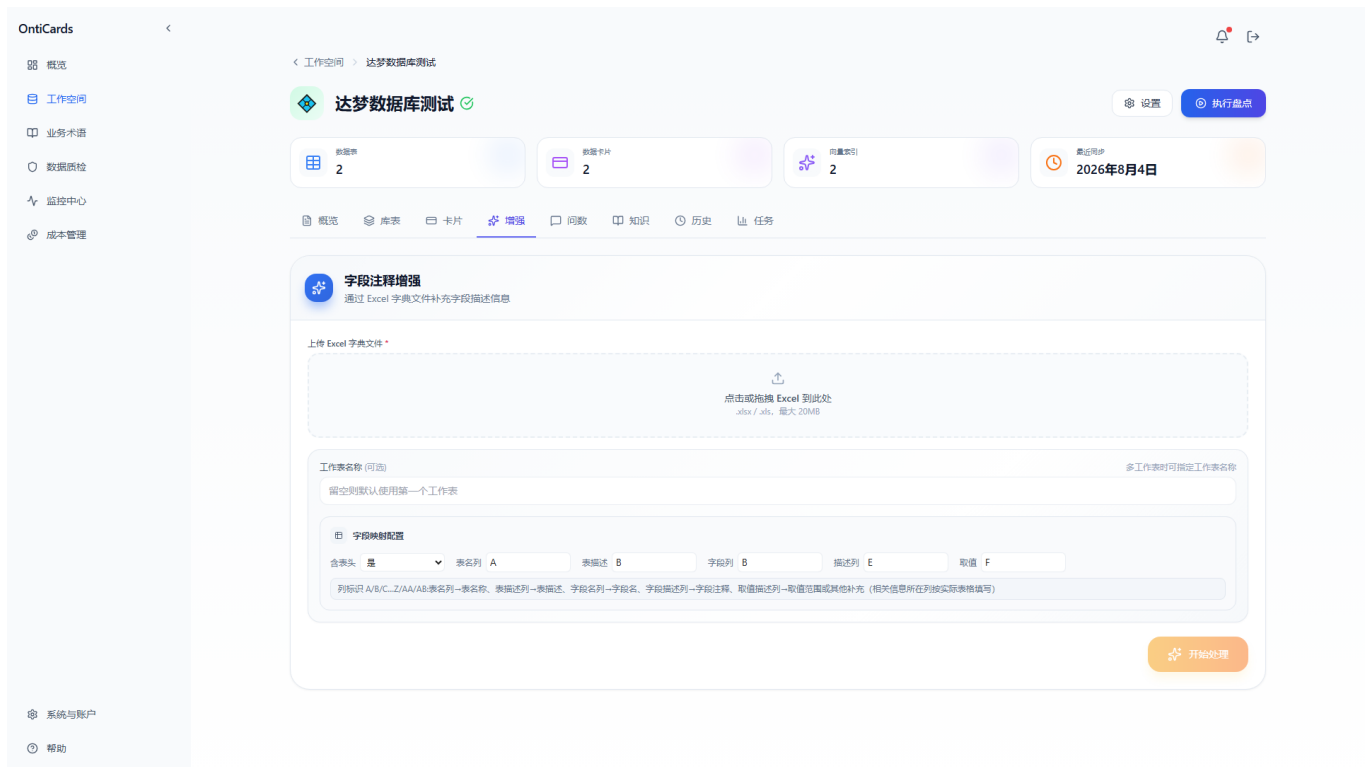
人工编辑：

点击「编辑」按钮可以人工修正：

- 调整表描述
- 修改/新增字段注释
- 增删标签
- 增删关键概念
- 增删适用场景

💡 **小技巧：**人工编辑后的卡片会被锁定，刷新数据源时不会被覆盖。系统也支持「重新生成」操作。

4.4 增强（字段注释增强）



「增强」Tab 用于 **通过 Excel 字典批量补充字段注释**，适合以下场景：

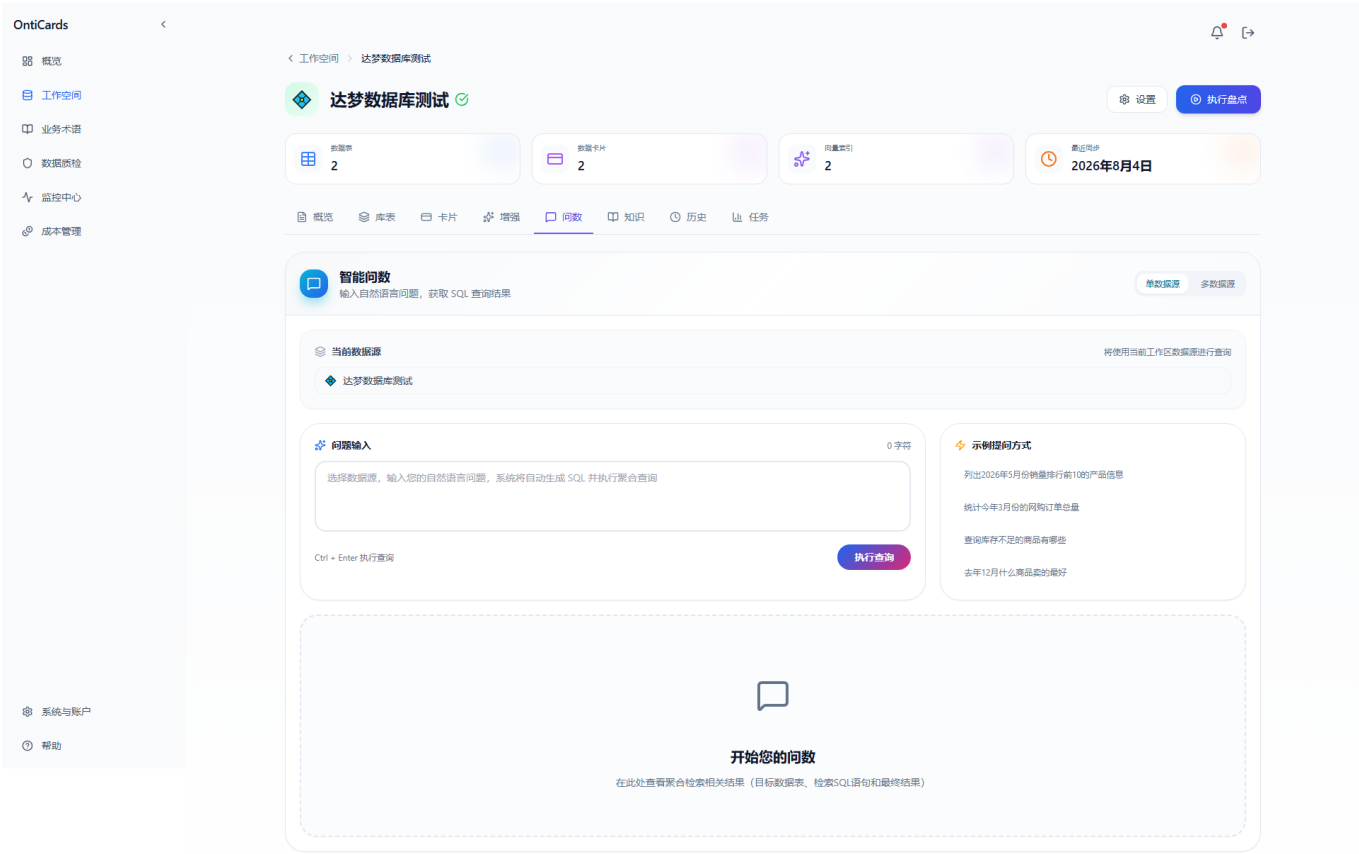
- 系统自动生成的注释不够准确
- 企业有现成的业务数据字典 Excel 文件
- 业务专家需要批量补全大量字段

使用流程：

1. 准备一个 Excel 文件（.xlsx / .xls），最大 20MB
2. 第一个工作表将被作为默认字典表
3. 配置列映射：选择哪一列是表名、字段名、字段注释
4. 点击「开始处理」
5. 处理完成后，对应字段的注释会写入数据卡片

💡 Excel 列映射可灵活配置（表名/字段名/字段注释对应的列），并支持一张工作表包含多个表名（不同行）。

4.5 问数（智能问数）



问数是 OntiCards 的核心交互入口。在该 Tab 下：

左侧主区域：

- **问题输入框：**支持多行输入，按 Ctrl + Enter 换行
- **「执行查询」按钮：**提交自然语言问题
- **模式切换：**「单数据源」 / 「多数据源」

当前数据源卡片：明确显示本次查询作用于哪个数据源

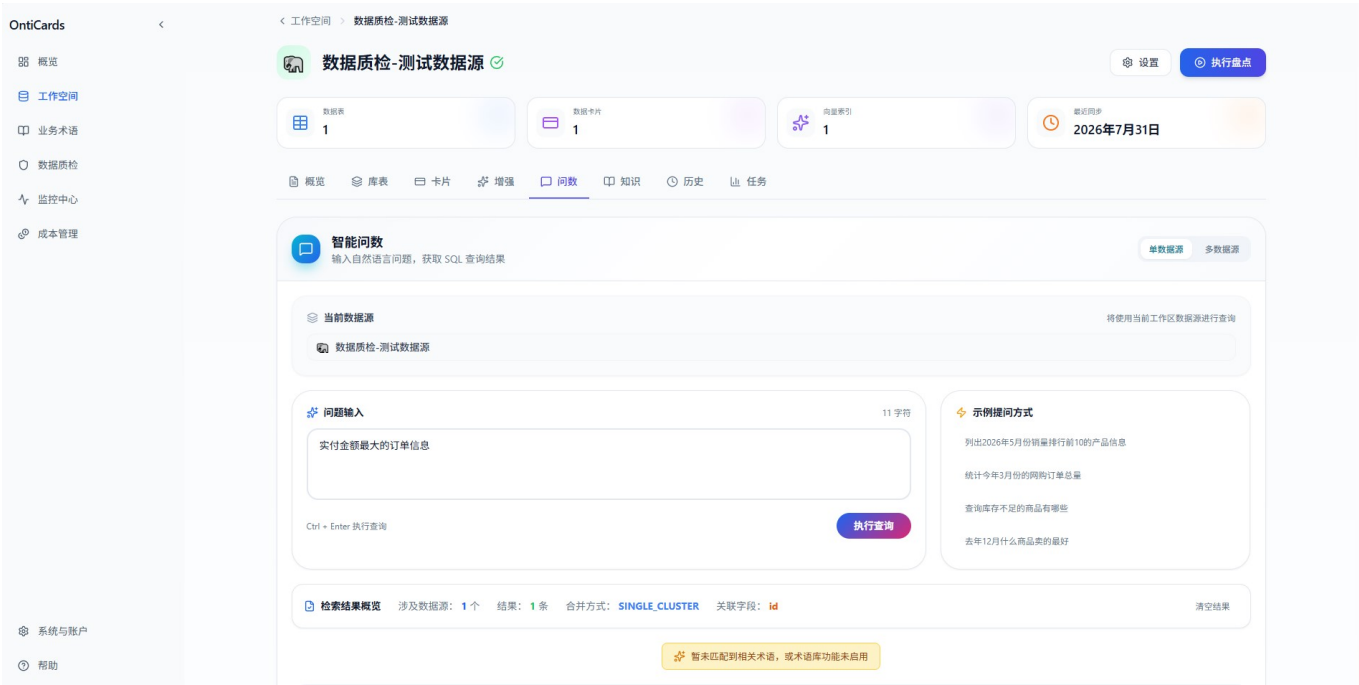
示例问题区（右侧「示例问句方式」）：点击即可填入示例问题，快速体验。

多数据源模式：

切换到「多数据源」后，可同时勾选多个数据源，系统会：

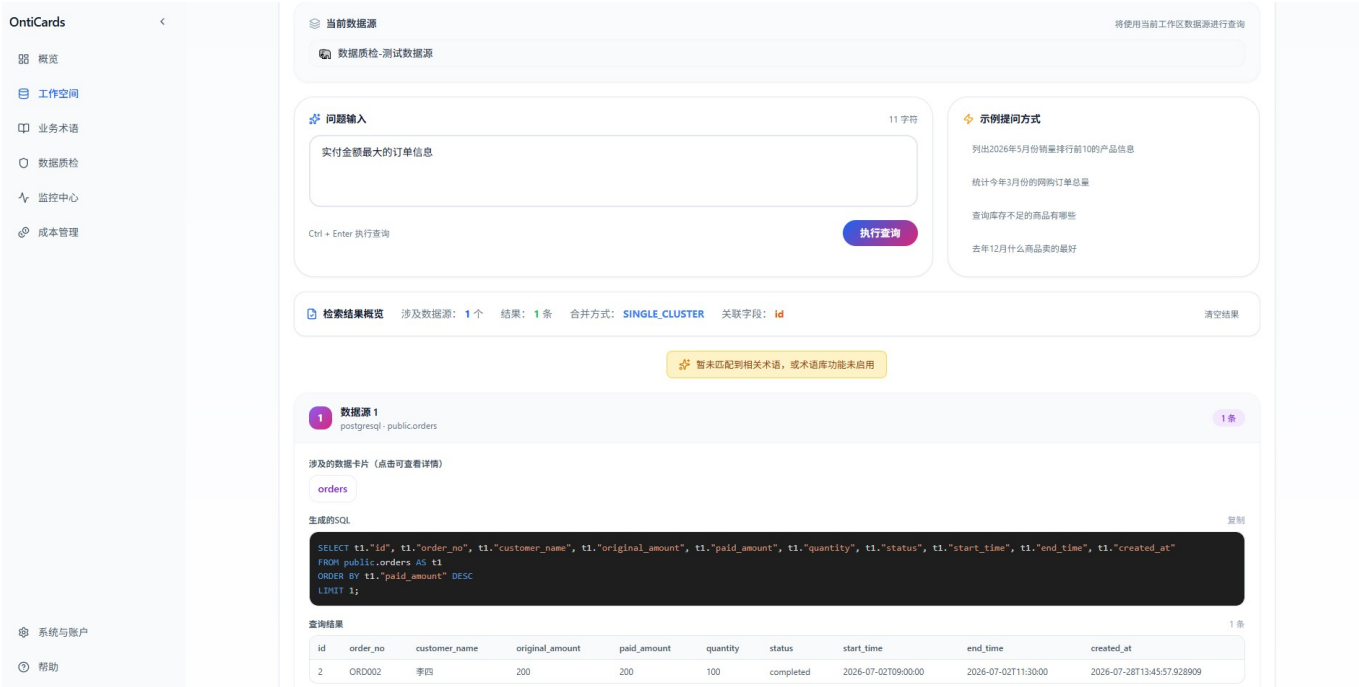
1. 理解问题
2. 自动规划需要查询哪些数据源
3. 跨库查询后对齐字段
4. 合并呈现结果

实际问数示例：



如上图所示，在「数据质检-测试数据源」下提问「实付金额最大的订单信息」：

- **顶部统计**：数据表/卡片/问数单/最近问数 4 个概览指标
- **来源选择**：明确告诉系统本次查询作用于哪个数据源
- **问题输入区**：右下角带快捷键提示 Ctrl + Enter
- **右侧示例**：点击示例问题即可快速填入
- **检索结果概览**：底部显示涉及数据源数、结果条数、合并方式、关键字段




如上图所示，问数结果区主要由 4 块组成：

区块	说明
----	----

区块	说明
检索结果概览	展示 涉及数据源 1 个 / 结果 1 条 / 合并方式 SINGLE_CLUSTER / 关键字段 id，右侧提供「清空结果」快捷操作
关联数据源	命中卡片 public.orders，右侧 1条 角标提示命中数量
生成 SQL（暗色代码块）	完整可复制，并在底部显示「暂未匹配到相关术语库」提示
查询结果表	表格化展示返回的字段值，最右列提供「复制 / 解释」动作

4.6 知识（业务术语库）

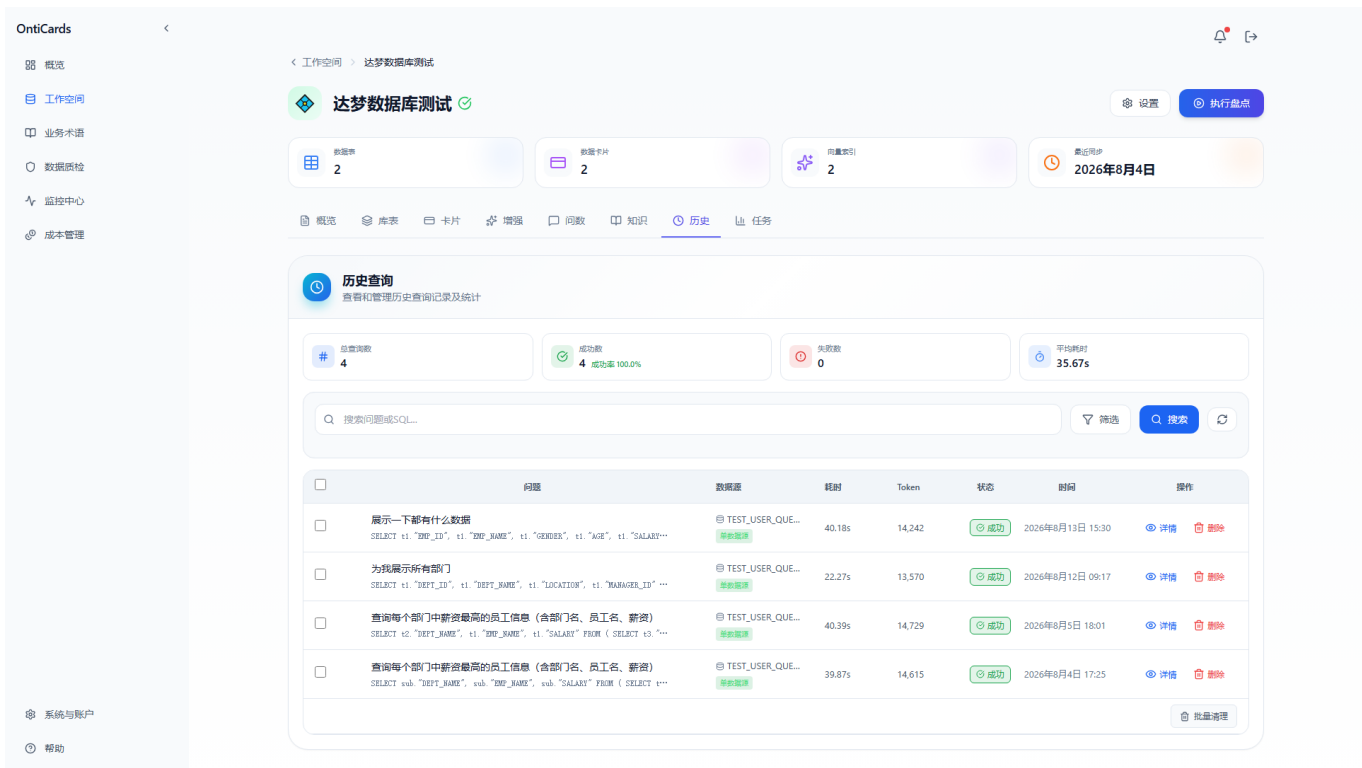


「知识」Tab 用于 **管理与该数据源关联的业务术语库**：

- 显示该数据源已关联的术语库列表
- 提供「添加术语库」「创建术语库」「刷新」操作
- 当数据源还没有关联任何术语库时，会以空状态引导

📖 业务术语库的具体创建与管理见 [第六章 业务术语库](#)。

4.7 历史（历史查询）



「历史」Tab 展示该数据源下的所有历史查询记录：

顶部统计：总查询数、成功率、失败数、平均耗时

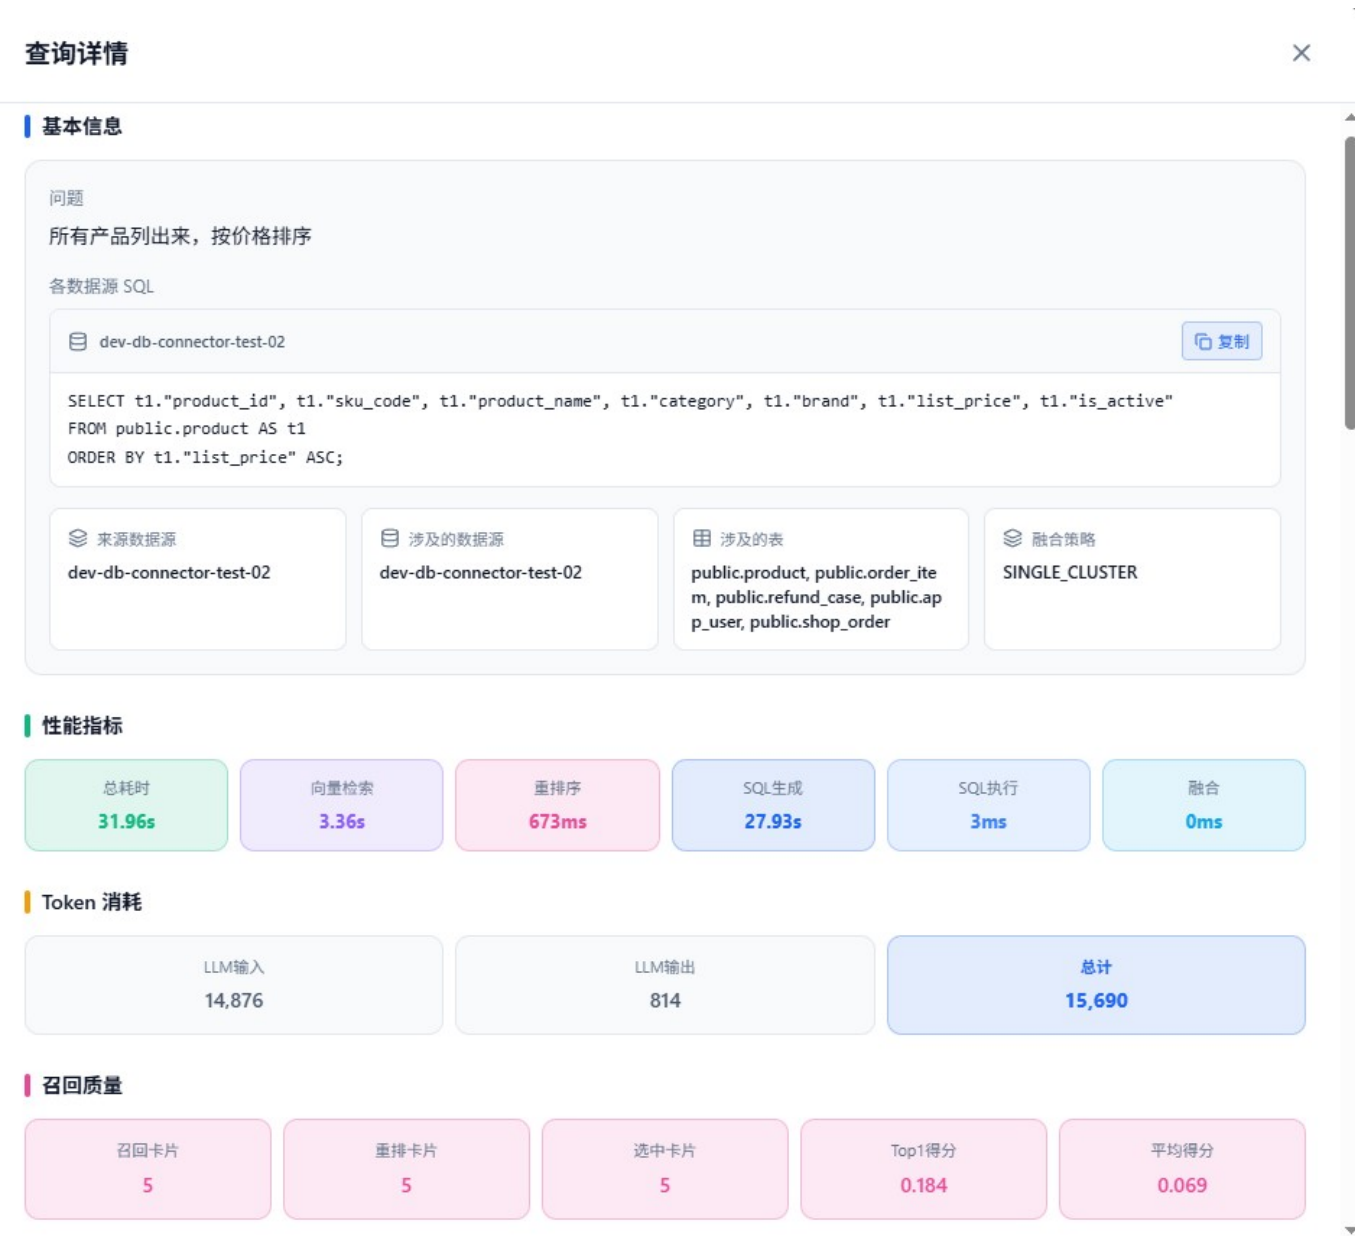
筛选与搜索：

- 搜索框：按问题关键词或生成的 SQL 片段搜索
- 「筛选」按钮：按时间范围、数据表、状态筛选
- 「搜索」按钮：执行筛选
- 「导出」按钮：导出当前结果

查询记录列表：

列	说明
问题	用户输入的自然语言问题
数据源	涉及的数据源
耗时	本次查询的总耗时（毫秒）
Token	消耗的 Token 数量
状态	成功 / 失败 / 超时
时间	提问时间
操作	详情（查看完整 SQL 与结果） / 删除

点击「详情」查看：



指标	含义
总耗时	从问题提交到结果返回的端到端耗时
向量检索	召回数据卡片 / 表的耗时
重排序	对召回结果重排序的耗时
SQL 生成	LLM 生成 SQL 的耗时
SQL 执行	在数据库执行 SQL 的耗时
融合	跨源结果对齐与合并耗时

③ Token 消耗

- LLM 输入 Token
- LLM 输出 Token
- 总计

💡 监控每次问数的 Token 消耗有助于成本管理（详见 [第十一章 成本管理](#)）。

④ 召回质量

指标	含义
召回数	候选表 / 卡片总数
重排数	经重排序后的候选数
选中数	最终被采纳的表 / 卡片数
Top1 得分	排名第一的候选与问题的语义相关度（0~1）
平均得分	全部候选的平均相关度

🎯 Top1 得分 < 0.5 通常表示问题表述不够清晰或业务术语未覆盖，可结合 [第五章 优化查询结果](#) 的建议调整。

⑤ **涉及的数据卡片**：点击后可查看数据卡片的详情信息

⑥ **查询结果记录**：本次查询的结果（表格形式呈现）

4.8 任务（数据盘点）



「任务」Tab 或右上角的「执行盘点」按钮用于管理与启动 **数据盘点任务**。其会分析表与表之间的关联关系，结果会用于：

- 提升多表 JOIN 查询的准确率
- 自动生成关系卡片
- 发现潜在的数据关系

支持两种盘点模式：

- **定向盘点**：选择目标表与参考表，做精细化盘点
- **全域盘点**：对全库所有表做整体盘点

创建定向盘点任务：

▼

🔍 执行定向盘点

操作步骤:

1. 点击「创建盘点任务」进入「定向盘点配置」页面
2. 在「目标表（需要推荐注释）」区勾选需要补充关系的表（如 product）
3. 在「参考表（提供参考注释）」区勾选提供候选关系的表（如 shop_order、order_item）
4. （可选）上传字典文件（CSV / Excel 格式，需包含 column_name 与 column_comment 列）
5. 点击「执行定向盘点」，系统开始分析

查看盘点结果·表关系确认:

盘点完成后进入「盘点结果」Tab，可查看系统推荐的关系列表：

定向盘点配置

针对特定表进行精细化的字段注释推荐和关系发现

×

数据源: 模拟数据源-电商场景-PgSQL刷新表列表

配置盘点盘点结果已完成

✔ 盘点完成

字段推荐数: 0 表关系数: 1 任务状态: completed

字段注释确认

表关系确认

已选择 1 / 1 个关系全选取消全选

☒	源表	源字段	目标表	目标字段	关系类型	基数	置信度	推荐原因
☒	product	product_id	→ order_item	product_id	外键	one_to_many	98%	product表的product_id是主键, order_item表的product_...

确认表关系

字段	说明
源表 / 源字段	已知的关联起点 (如 product.product_id)
目标表 / 目标字段	候选的关联终点 (如 order_item.product_id)
关系类型	外键 / 同名字段 / 业务关联
基数	one_to_one / one_to_many 等
置信度	系统对这条关系推荐的可信度 (0~100%)
推荐原因	模型给出的判定理由

✔ 勾选确认无误的关系，点击「确认表关系」即可生成 **关系卡片**。

盘点结果·关系图谱视图：



在「盘点结果」Tab 切换至「关系图谱」子视图，可以更直观地看到表与表之间的 **关系连线** 和整体连接关系，便于从全局理解数据模型。

关系卡片详情：

点击某条已确认关系，可进入「关系卡片」详情页：



关系卡片以 **业务语言** 解释一条关系的含义，包括：

- **关联字段**：参与关联的字段（如 `product.product_id ↔ order_item.product_id`）
- **业务含义**：用自然语言解释"为什么这两张表能这样连"
- **业务角色**：明确主表（商品）与从表（订单）的角色划分
- **关系类型**：外键关联 / 同名字段 / 业务推断
- **推荐连接**：LEFT JOIN / INNER JOIN / 全连接
- **推荐依据**：模型给出该推荐的原因（如字段类型一致、值域分布匹配等）
- **整体置信度**：模型对该关系的总体评分（如 98%）
- **适用场景**：这条关系适合回答什么类型的业务问题
- **融合策略建议**：基于主从数据展示的预聚合建议
- **联表查询建议**：可直接套用的 SQL 模板

🔍 数据盘点的更多操作细节见 [第七章 数据盘点](#)。

五、智能问数（自然语言查询）

5.1 基本查询

在「问数」Tab 的输入框中输入日常问题，例如：

- 列出 2025 年 5 月份销售排行榜前 10 的产品信息
- 统计今年 3 月份各部门的订单总量
- 查询库存不足的商品有哪些
- 去年 12 月份什么商品卖得最好

按回车或点击「执行查询」，系统会：

1. **理解问题**：识别意图、涉及的时间范围、维度、指标
2. **检索元数据**：匹配相关表与字段
3. **生成 SQL**：根据数据库方言生成可执行 SQL
4. **安全校验**：拦截非 SELECT 语句
5. **执行查询**：执行 SQL 并返回结果
6. **结果展示**：以表格、图表形式展示

5.2 多步推理查询

OntiCards 支持 **多步推理**（Multi-step Reasoning）。系统会将复杂问题拆解为多个子问题，依次执行后合并结果。

示例问题：

“查询上月销量前 10 的商品，这些商品目前的库存分别是多少？”

系统会拆解为：

1. 取上月销量前 10 的商品
2. 查这 10 个商品的当前库存
3. 合并两张结果

5.3 跨源融合查询

前置条件：

- 已添加多个数据源
- 业务术语库已配置并启用
- 切换到「多数据源」模式

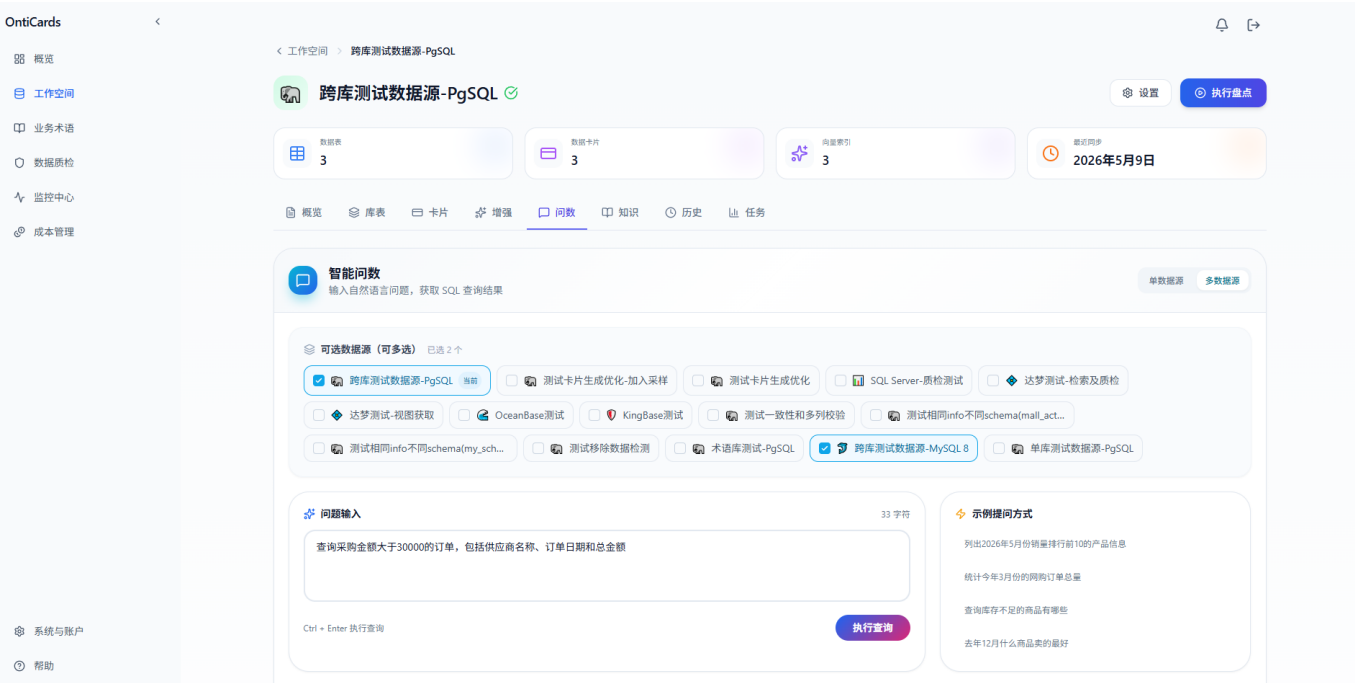
示例问题：

“电商系统的订单与 CRM 的客户档案对比，找出哪些 VIP 客户最近 3 个月未下单？”

系统会：

- 1. 解析出需要查「订单库」与「CRM 库」
- 2. 在订单库中找最近 3 个月的订单
- 3. 在 CRM 库中找 VIP 客户
- 4. 跨库对齐结果

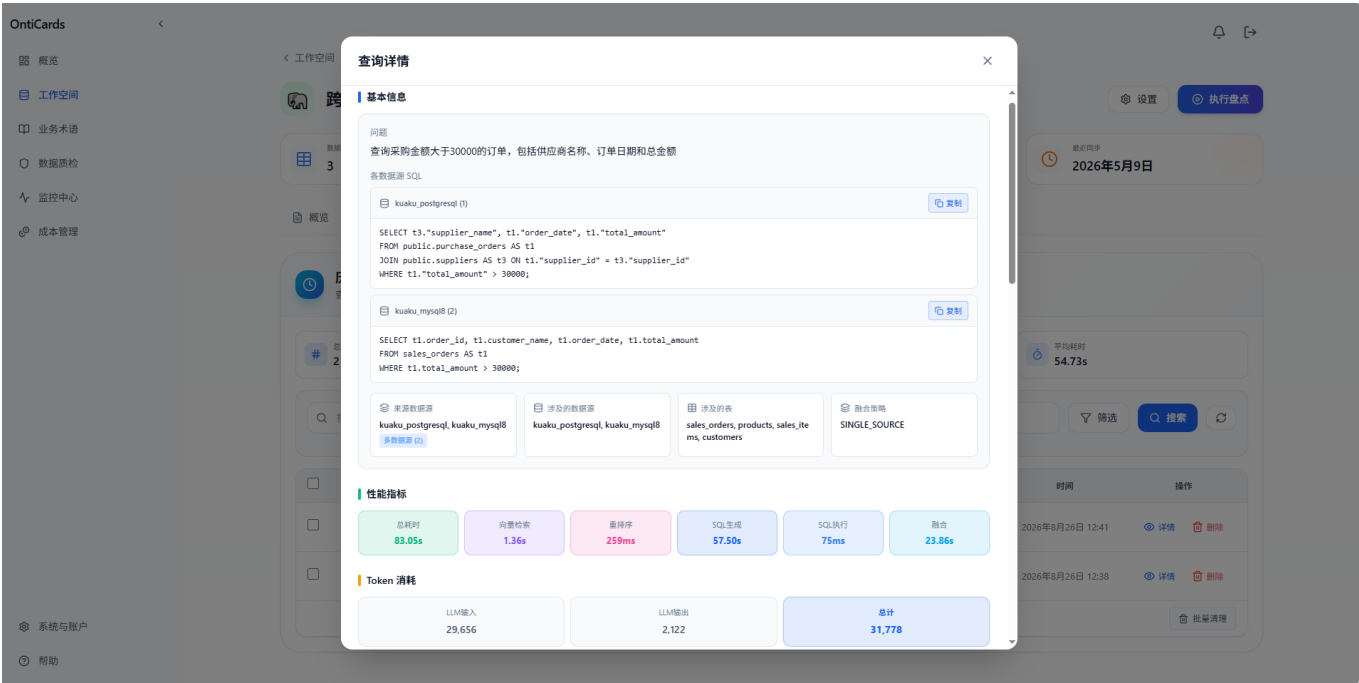
跨库查询示例（输入阶段）：



如上图所示：

- **顶部统计区**：数据表 3 张 / 数据卡片 3 张 / 问数单 3 个 / 最近同步 2026 年 5 月 9 日
- **多数据源开关**：「多数据源」已启用（单数据源 → 多数据源 一键切换）
- **可选数据源**（多选）：共 14 个数据源可勾选，已选 2 个（高亮态）
- **问题输入区**：提问「查询采购金额大于30000的订单，包括供应商名称、订单日期和总金额」33 字符
- **示例问句方式**（右侧）：点击可快速填入问题

跨库查询结果融合（输出阶段）：



查询详情弹窗内清晰展示 **跨源融合** 的全链路：

区块	关键内容
基本信息	用户问题、查看数据 SQL
各数据源 SQL（双段）	- kuaku_postgresql：purchase_orders JOIN suppliers，筛选 total_amount > 30000 - kuaku_mysql：sales_orders 筛选 total_amount > 30000
关联信息 4 卡	来源数据源 / 关联数据源 / 涉及表（purchase_orders + suppliers + sales_orders + products + customers） / 融合指标 SINGLE_SOURCE
性能指标	总耗时 83.05s / 向量检索 1.36s / 重排序 259ms / SQL 生成 57.50s / SQL 执行 75ms / 融合 23.86s
Token 消耗	LLM 输入 29,656 / LLM 输出 2,122 / 总计 31,778

💡 跨库查询的融合方式（SINGLE_SOURCE / MULTI_CLUSTER / JOIN_FUSION 等）由系统根据问题复杂度自动选择，结果详情中可清晰看到每一步耗时。

5.4 查询结果解读

查询结果页通常包含以下信息：

- **数据表格**：查询返回的核心数据
- **数据来源**：明确标注来自哪个数据库、哪些表
- **查询说明**：系统是如何理解你问题的，包括：

- 识别到的时间范围
- 识别的筛选条件
- 选择的表与字段
- 应用的业务术语
- **生成的 SQL**：可一键复制
- **提示与告警**：哪些条件被识别、哪些被忽略、原因是什么

实际查询结果示例：

OntiCards

概览

工作空间

业务术语

数据质检

监控中心

成本管理

系统与账户

帮助

当前数据源

数据质检-测试数据源

将使用当前工作区数据源进行查询

问题输入

11 字符

实付金额最大的订单信息

Ctrl + Enter 执行查询

执行查询

示例提问方式

列出2026年5月份销量排行前10的产品信息

统计今年3月份的网购订单总量

查询库存不足的商品有哪些

去年12月什么商品卖的最好

检索结果概览

涉及数据源：1 个

结果：1 条

合并方式：SINGLE_CLUSTER

关联字段：id

清空结果

暂未匹配到相关术语，或术语库功能未启用

数据源 1

1 条

postgres - public.orders

涉及的数据卡片（点击可查看详情）

orders

生成的SQL

复制

SELECT t1."id", t1."order_no", t1."customer_name", t1."original_amount", t1."paid_amount", t1."status", t1."created_at"
FROM public.orders AS t1
ORDER BY t1."paid_amount" DESC
LIMIT 1;

查询结果

1 条

id	order_no	customer_name	original_amount	paid_amount	status	created_at
2	ORD002	李四	200	200	completed	2026-07-28T13:45:57.928909

如上图所示，提问「实付金额最大的订单信息」后，系统返回：

- **检索结果概览**：涉及 1 个数据源，返回 1 条结果，合并方式 SINGLE_CLUSTER，关键字段 id
- **数据源 1**（1 条）：关联的卡片为 public.orders
- **生成 SQL**（高亮代码块，可一键复制 / 复制 / 解释）：

```
SELECT t1."id", t1."order_no", t1."customer_name",  
       t1."original_amount", t1."paid_amount",  
       t1."status", t1."created_at"  
FROM public.orders AS t1  
ORDER BY t1."paid_amount" DESC  
LIMIT 1;
```

- **查询结果表**：展示关键字段值（id / order_no / customer_name / original_amount / paid_amount / status / created_at）

💡 未配置相关术语库时，系统会在底部给出提示「暂未匹配到相关术语库，或术语库功能未启用」，可按需去 [第六章 业务术语库](#) 创建。

5.5 优化查询结果

如果结果不符合预期，按以下顺序排查：

- 1. **查看「查询说明」**：理解系统的解析逻辑
- 2. **补充数据卡片**：表与字段的描述越丰富，问数越准确（可手动调整或上传字典文件）
- 3. **补充业务术语库**：把"高价值客户"等业务概念显式定义，助于系统理解专业术语名词
- 4. **调整提问方式**：更具体地表达意图
 - 增加时间范围限定
 - 明确排序方式
 - 明确输出格式
- 5. **启用数据盘点**：补充表之间的关系，提升 JOIN 准确率

提问技巧：

场景	不好的问法	好的问法
时间范围	"最近的订单"	"最近 30 天的订单"
排序	"最多的客户"	"消费金额前 10 名的客户"
维度	"产品的销售"	"按品类分组的销售总额"
过滤	"活跃用户"	"近 7 天登录过的用户"

六、业务术语库

6.1 什么是业务术语库

业务术语库（Glossary）用于 **把企业内部的业务概念显式定义**，让系统真正"懂业务语言"。

典型例子：

业务术语	系统理解
高价值客户	VIP等级 IN ('钻石', '金卡') AND 累计消费 > 10000
核心商品	产品分类 IN ('A类', 'B类')
活跃用户	最近 30 天登录次数 >= 3
滞销商品	入库超过 90 天 且 销量 < 10

6.2 创建术语库

进入「业务术语」页面：



步骤：

1. 点击「新建术语库」按钮
 2. 填写：
 - 术语库名称（如"销售术语库"）
 - 行业分类（可选）
 - 描述（说明该术语库的应用范围）
 3. 在术语库内添加业务术语，每条术语包含：
 - **术语名称**：业务口径（如"高价值客户"）
 - **别名/同义词**：可选（如"VIP 客户""重点客户"）
 - **定义**：用 SQL 表达式或自然语言定义
 - **关联字段**：关联到具体的库.表.字段
 4. 启用术语库（开关开启后，问数时才会被使用）
- 💡 系统提供"财务术语库""电商零售术语库"等行业模板，可作为起点。

术语库详情示例（财务术语库）：



如上图所示，进入「财务术语库」后可看到完整的术语卡片列表，每张卡片包含：

- **术语名称**：如「营业收入」「营业成本」「毛利」「毛利率」「净利润」等
- **状态徽标**：「已启用」/「已停用」一键切换
- **别名/同义词**：支持多个（如「毛利润」对应「毛利」）
- **类型标签**：标记该术语的种类（销售类 / 成本类 / 费用类 / 资产类 / 风险类等）
- **定义**：用自然语言 + 公式（如「毛利率 = 毛利 / 营业收入 × 100%」）

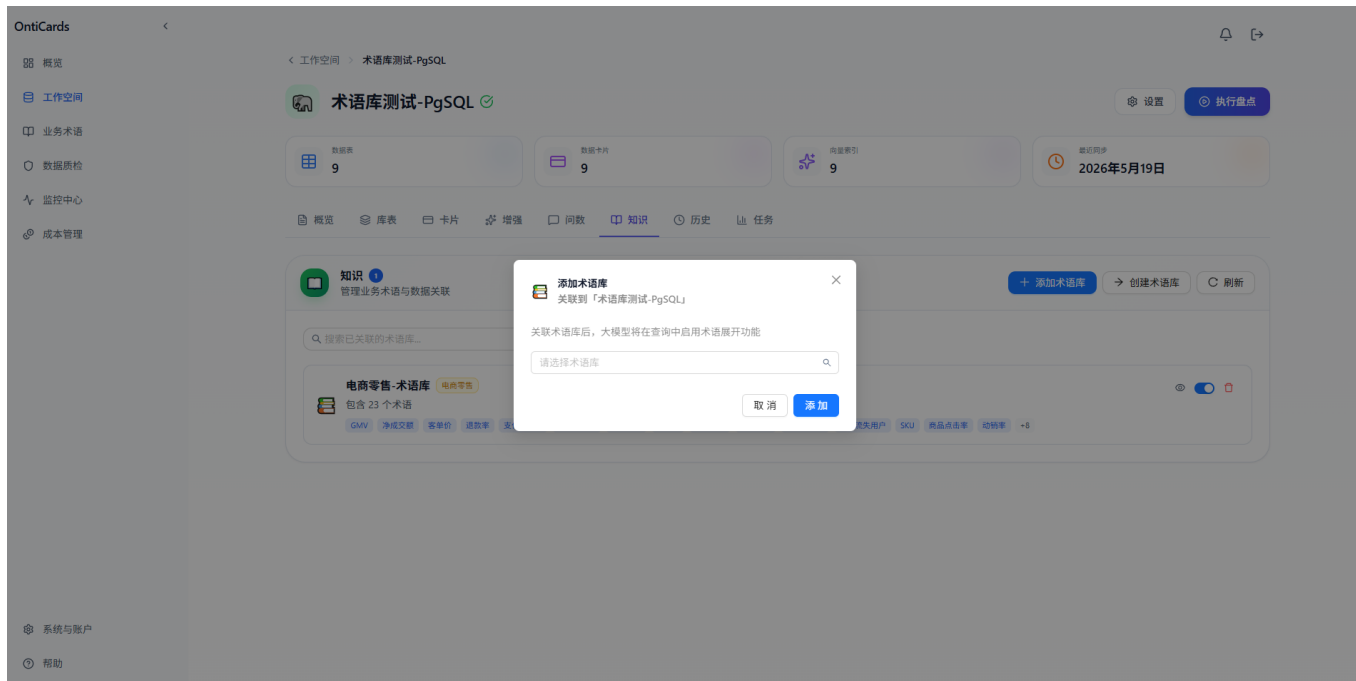
常用财务术语速查：

分类	术语	系统理解
收入类	营业收入	企业从经营业务中获得的收入，按权责发生制确认
收入类	营业成本	为取得营业收入而发生的直接成本，如原材料、人工、制造费用等
利润类	毛利	营业收入 - 营业成本，反映主营业务的盈利能力和直接成本控制水平
利润类	毛利率	$\text{毛利} / \text{营业收入} \times 100\%$
利润类	净利润	营业收入 - 营业成本 - 营业外收入 - 营业外支出 - 所得税费用
利润类	净利率	$\text{净利润} / \text{营业收入} \times 100\%$
费用类	销售费用	为销售产品或提供劳务而发生的费用，包括广告费、推销员工工资、销售机构经费
费用类	管理费用	企业行政管理为生产经营活动所发生的费用
风险类	资产负债率	$\text{总负债} / \text{总资产} \times 100\%$
流动性	现金净流量	现金流入 - 现金流出

6.3 在数据源中关联术语库

创建好的术语库需要 **关联到具体数据源** 才会被使用。

1. 进入数据源详情 → 「知识」Tab
2. 点击「添加术语库」
3. 选择目标术语库
4. 关联后，该数据源的所有问数都会自动展开该术语库中的概念



七、数据盘点

数据盘点是 **AI 自动分析表与表之间关系** 的能力，能显著提升多表 JOIN 查询的准确率。

7.1 全域盘点

适用场景：首次接入数据源，希望系统自动发现所有表的关系。

步骤：

1. 进入数据源详情 → 「任务」Tab
2. 选择「全域盘点」模式
3. 点击「创建盘点任务」
4. 等待系统完成（表数越多耗时越长）
5. 在任务列表中查看进度与结果

6. 完成后系统会生成 **关系卡片**，并自动应用到问数引擎

7.2 定向盘点

适用场景：

- 只想盘点几张核心业务表
- 系统推荐的关系不准确，需要补充参考
- 人工对部分表有明确的关系预期

步骤：

1. 进入「任务」Tab → 「定向盘点」
2. 选择 **目标表**（需要补充关系的表）
3. 选择 **参考表**（提供候选关系的表）
4. （可选）上传字典文件辅助字段推荐
5. 点击「执行定向盘点」
6. 系统会分析并推荐字段间的关系
7. 人工确认 / 修正后点击「确认表关系」生成 **关系卡片**

🔧 配置页与盘点结果视图的详细说明见 §4.8 任务（数据盘点）。

7.3 盘点结果管理

盘点完成后，系统会生成两类核心产物：

- **关系列表**（表关系确认视图）：列出全部候选关系，可逐条勾选确认
- **关系卡片**：每条确认的关系都会生成一张「关系卡片」，用于问数时自动调用

关系卡片生命周期：

1. **生成**：盘点结果确认后自动产出
2. **应用**：在问数涉及相关表时被自动召回
3. **编辑**：支持人工微调（业务含义、推荐连接、置信度等）
4. **回滚**：关系错误时可删除并重新盘点

🔧 关系卡片详情与字段说明见 §4.8 任务（数据盘点）。

八、字段注释增强

当 AI 自动生成的数据卡片描述不够准确时，可通过 **上传 Excel 数据字典** 的方式批量补充字段注释。

8.1 准备 Excel 字典文件

要求：

- 文件格式：.xlsx 或 .xls
- 文件大小：≤ 20MB
- 默认读取 **第一个工作表**
- 必须包含表名、字段名、字段注释三列（顺序不限，可在上传时映射）

示例：

表名	字段名	字段注释
orders	order_id	订单编号（主键）
orders	user_id	下单用户 ID
orders	amount	订单金额（元）
orders	created_at	下单时间

8.2 上传与配置

1. 进入数据源详情 → 「增强」Tab
2. 上传 Excel 文件
3. 配置 **列映射**：

字段	说明
表名	字典中哪一列是表名
字段名	字典中哪一列是字段名
字段注释	字典中哪一列是字段注释

1. （可选）工作表名称：留空则使用第一个工作表
2. 点击「开始处理」

8.3 查看增强结果

处理完成后：

- 数据卡片中对应字段的注释会被更新
- 「库表」Tab 中字段的描述列会显示新的注释
- 后续问数时系统会优先使用增强后的注释

💡 **批处理建议：**字典列名支持 A/B/C/E 等 Excel 列号表示，也支持下拉选择具体列名。

九、数据质检

OntiCards 内置完整的数据质量检查能力。

9.1 规则库管理

进入「数据质检」页面：



顶部指标卡：

- 规则库总数

- 启用的规则数
- 质检报告总数
- 当前质量评分

质检总览：

环形图展示「活跃规则」「启用规则」「总规则数」的占比，以及 **当前质量评分**（如 81.1 分）。

质量维度评估：

按维度展示得分，包括：

- 有效性（如 86.9）
- 一致性（如 77.8）

规则类型分布：多对象检查、一致性检查、唯一性检查、日期检查 等

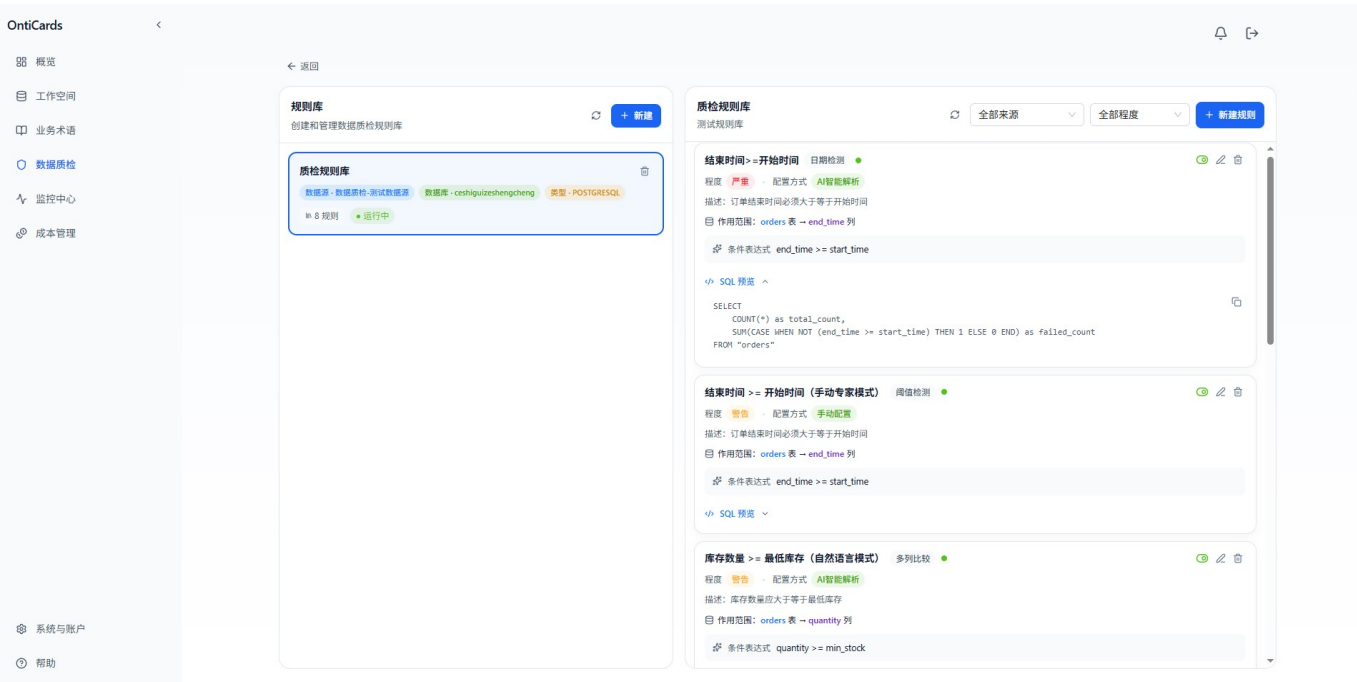
关键发现：列出问题最严重的字段

快捷入口：

- 新建规则库
- 创建规则
- 查看报告
- 整库报告

最近报告：展示历史报告卡片，可点击查看详情。

规则库管理页（点击「规则库」Tab 进入）：



页面采用 **左右双栏布局**：

- 左侧「规则库」列表**：显示所有规则库（如「浙报-有道理-测试数据源」），含数据源/Schema 标识、规则数量与运行状态

▪ 右侧「质检规则库」详情：

- **顶部筛选**：按「全部数据源」「全部程度」过滤
- **新增规则按钮**：唤起创建规则弹窗
- **规则列表**（每行一条规则）：展示规则名、程度（严重/警告）、AI 解析、作用范围（schema.table + 列名）、条件表达式（自动转 SQL 预览）、启用/编辑/删除三件套操作

💡 同一条规则可被多个数据源复用。规则级别可设置为「严重（critical）」「警告（warning）」两种，决定问题严重程度与报告评分。

9.2 创建质检规则

步骤 1：创建规则库

1. 在「数据质检」首页点击「新建规则库」
2. 填写：
 - 规则库名称
 - 关联的数据源
3. 保存后即可在规则库内添加规则

步骤 2：添加规则

支持三种创建方式：

创建规则



- 手动专家模式
- 自然语言模式
- 单条模板建规则

通过自然语言描述质检需求，系统自动识别并生成规则配置与 SQL。

信息

规则名称 *

规则类型

严重程度

例如：订单金额不能为负

空值检测

警告

目标表

目标列

可选

先选表

规则描述 *（用于生成校验SQL的自然语言）

例如：检查订单金额字段必须大于0，如果为负则记录一条违规

目标表、目标列、规则类型均为可选参数，AI会自动推断，指定可提高解析准确度。

请输入规则描述并进行AI解析

AI 智能规则建议 基于数据源结构智能推荐质量检测规则

获取建议

点击「获取建议」按钮，AI 将分析当前数据源并推荐质量检测规则

请输入规则描述并进行AI解析

创建

- **手动专家模式**：完全手工填写规则名、目标表/列、SQL 条件（适合复杂业务规则）
- **自然语言模式**：用一句话描述需求，AI 自动生成 SQL 与配置（推荐，门槛最低）
- **单条模板建规则**：从预设模板（空值检测/一致性/唯一性/范围 等）挑选并填入参数

方式一：模板模式

从预设模板中选择（最快捷）：

- 邮箱格式校验
- 手机号格式校验
- 身份证号校验

- 金额非空检查
- 日期范围检查
- ...

方式二：AI 模式（推荐）

用自然语言描述规则，系统自动生成配置：

- "检查订单表的金额是否大于 0"
- "检查用户表手机号是否为 11 位"
- "检查邮箱格式是否正确"

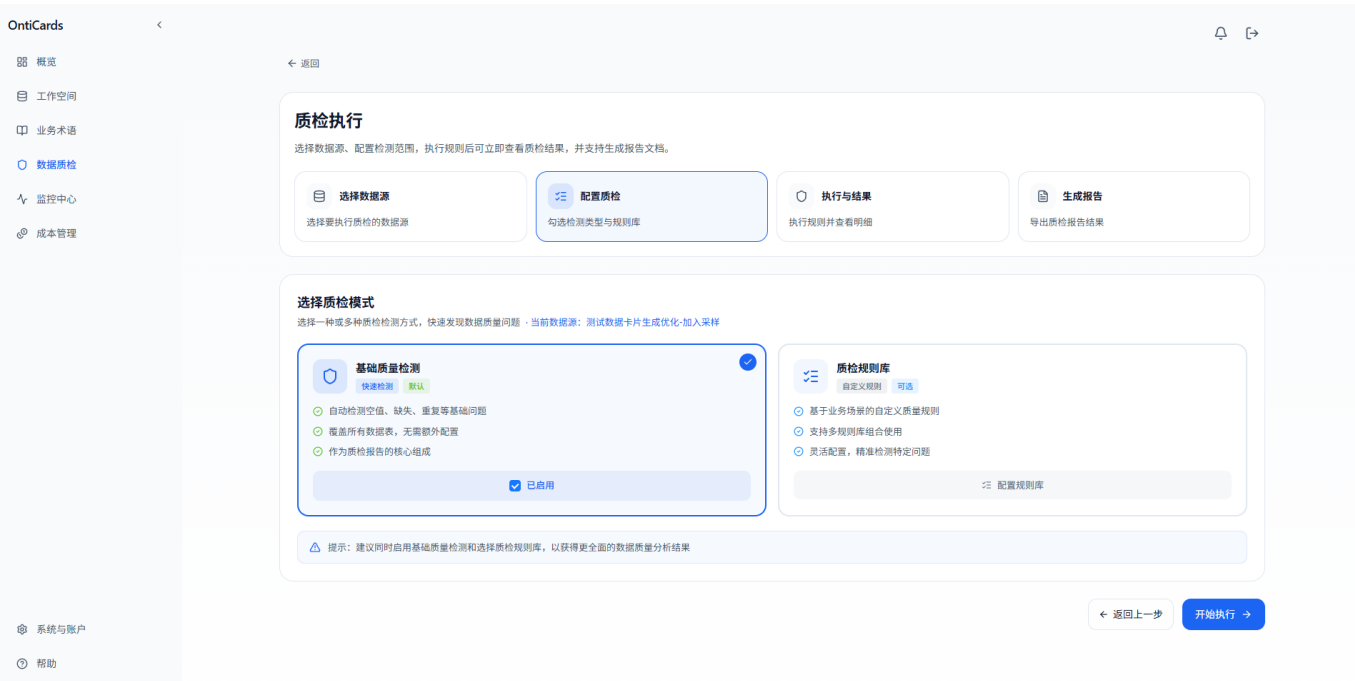

方式三：手动模式

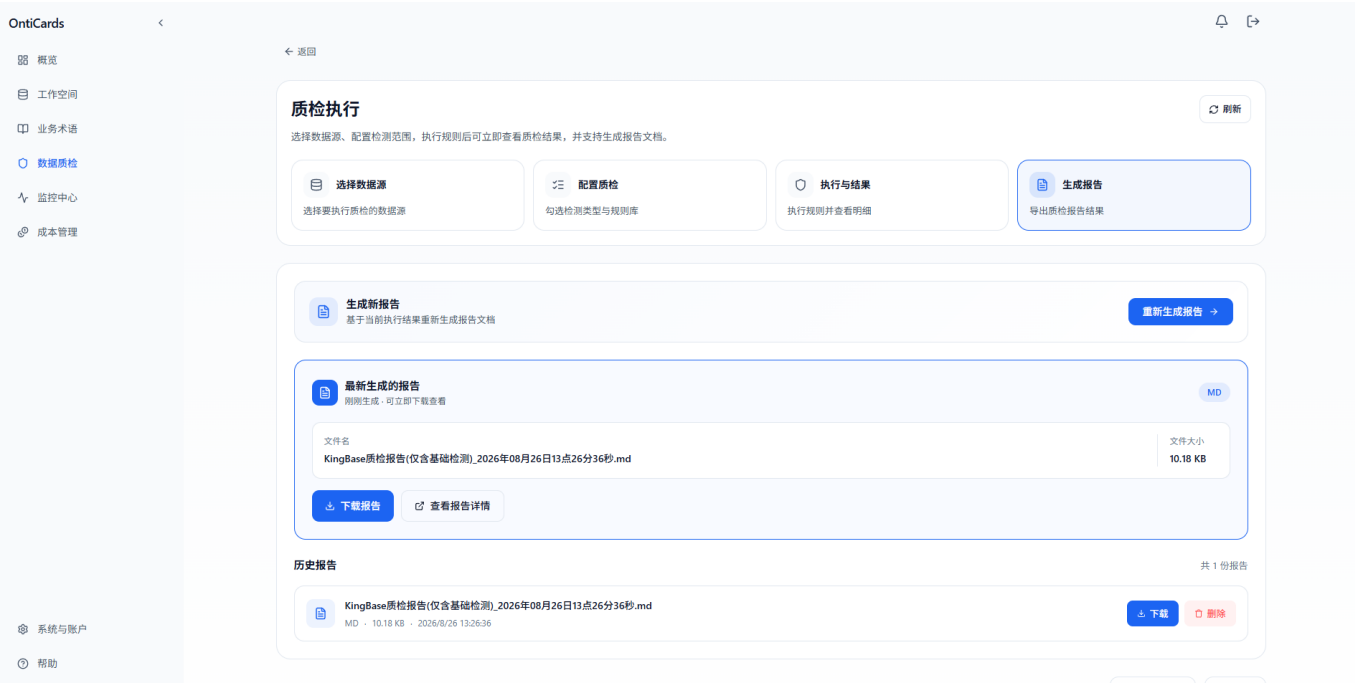
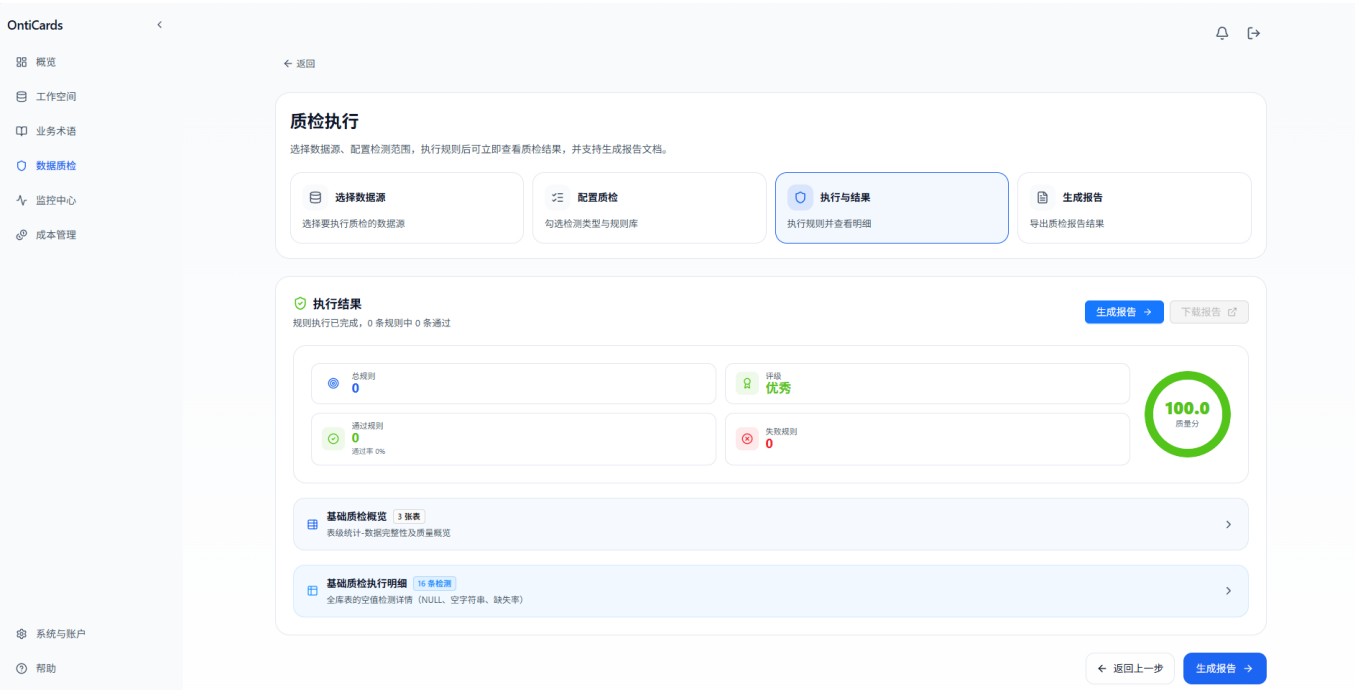
直接配置规则参数：

规则类型	适用
非空检查	必填字段不能为空
唯一性检查	主键/唯一索引字段
格式校验	邮箱、手机号、身份证
范围检查	数值/日期范围
枚举值检查	字段值必须在指定集合内
正则匹配	自定义正则
跨表比对	外键引用一致性

9.3 执行质检

1. 进入数据源 → 「数据质检」或顶层「数据质检」
2. 选择规则库或指定规则
3. 点击「开始执行」
4. 等待执行完成（根据数据量大小耗时不同）
5. 在执行结果页查看详细情况
6. 可下载质检报告物理文件





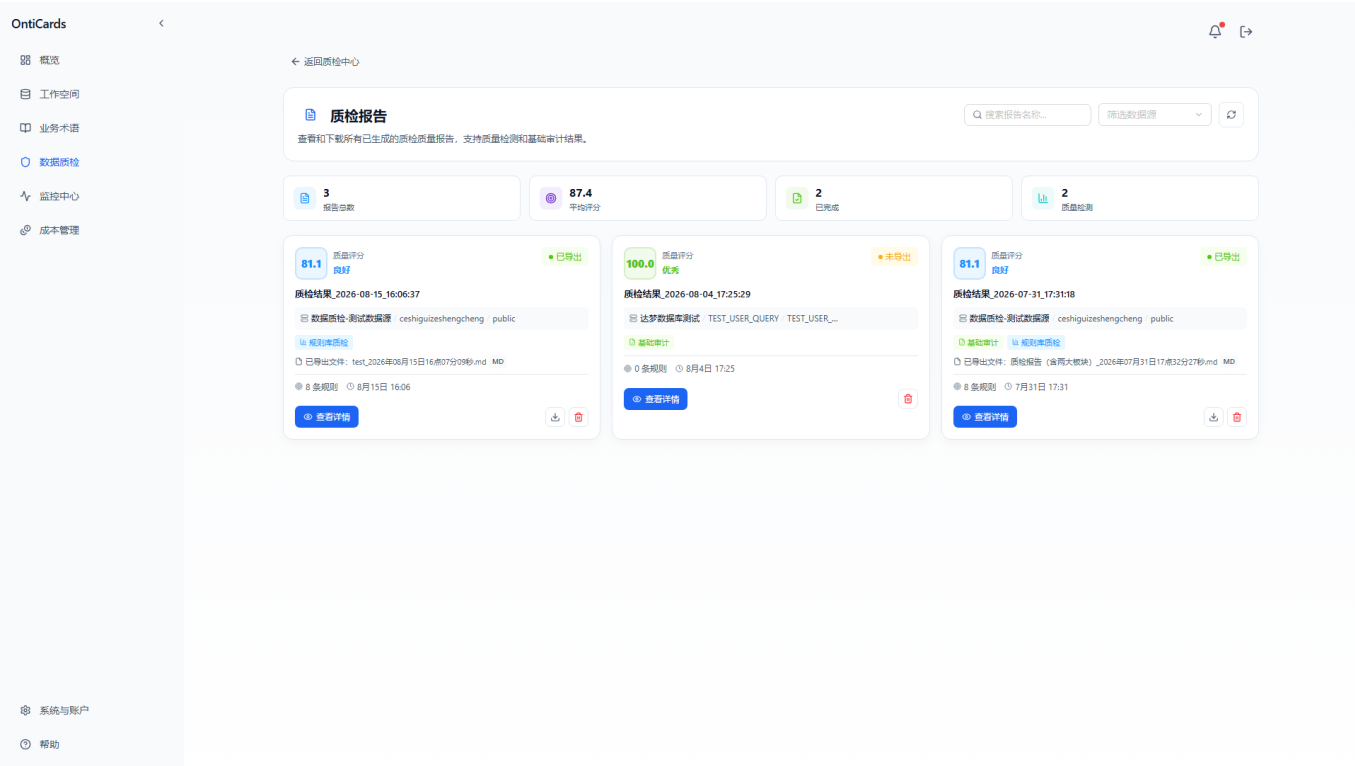
9.4 质量评分

等级	分数范围	说明
优秀	≥ 95	数据质量非常好
良好	85 - 95	数据质量良好
一般	70 - 85	有改进空间
较差	60 - 70	问题较多

等级	分数范围	说明
差	< 60	严重问题

评分依据：通过率、平均问题数、问题严重程度加权计算。

9.5 质检报告



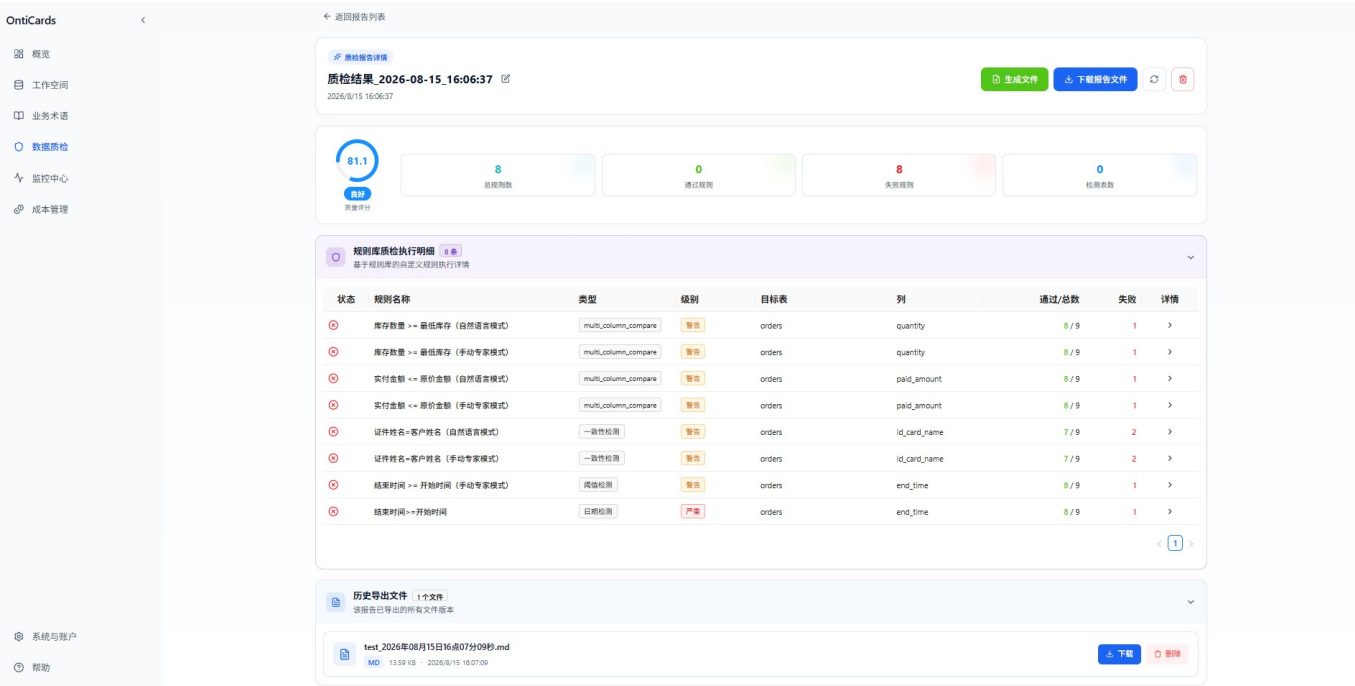
报告列表页展示所有历史报告卡片，每张卡片显示：

- 报告 ID
- 质检对象（数据源、Schema）
- 平均得分
- 已导出 / 未导出状态
- 已查/总表数
- 起始/截止时间
- 操作按钮：查看详情、下载、删除

报告详情包含：

- 各维度评分明细
- 每张表的健康分
- 每条规则的检查结果（通过/失败/异常数）
- 失败样本（前 N 条）

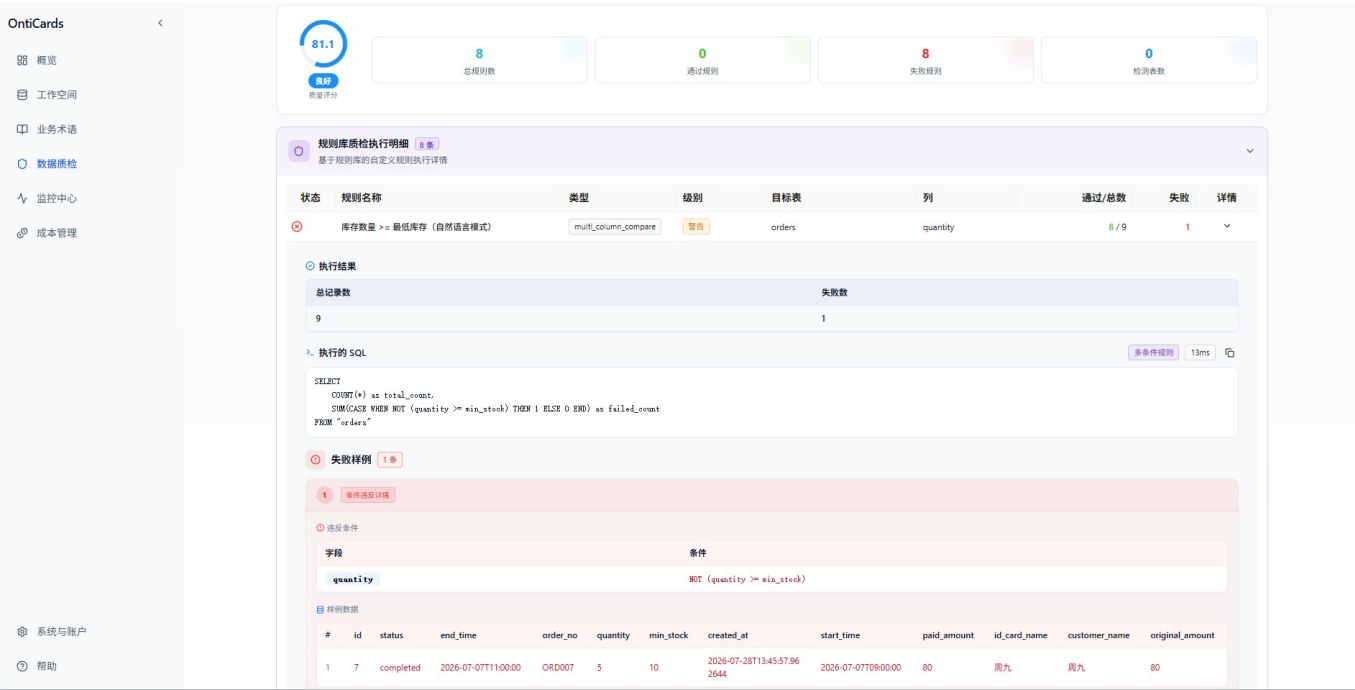
单条报告详情页：



进入单条报告后可见：

- **报告头**：质检结果评分、生成时间，并提供「生成文件」「下载报告文件」「刷新」「删除」4 个全局操作
- **质量评分卡**（左上）：环形进度展示「良好（81.1）」等级，含总规则数（8）、通过数（0）、失败数（8）、检测表数（0）
- **规则库质检执行明细**：每条规则一行，字段含状态、规则名称、类型、级别（警告/严重）、目标表/列、通过/总数、失败数、详情入口
- **历史导出文件**：报告底部保留历史下载文件，可重新下载或删除

规则执行明细（点击「详情」展开）：



单条规则的执行详情展示 3 大区块：

区块	内容
执行结果	总记录数、失败数（饼图化）
执行的 SQL	可一键复制或重新生成，右侧显示耗时（如 13ms）
失败样例	命中条件 + 字段（quantity 死否表达式 quantity >= min_stock）+ 样例数据（最多前 N 条，含完整字段值）

下载报告文件（点击「下载报告文件」按钮生成）：

文件

大纲

▼ 质检结果_2026-08-15_16:06:37

一、基本信息

二、质量概览

三、执行明细（基于规则库）

▶ 四、失败样例明细

▶ 五、智能总结

五、智能总结

规则库质检分析

1. 整体概况

本次质检共执行 8 条规则，规则维度通过率为 0%（8 条规则均发现异常）。目标表 orders 共检查 9 条记录，累计发现 5 条独立异常记录，数据影响率高达 55.56%。问题包含 1 个严重（critical）级别和 7 个警告（warning）级别，整体数据质量评级为“较差”，核心业务逻辑存在明显漏洞，需紧急干预。

2. 失败规则详情

以下为失败规则详情（按失败率降序排列）：

规则名称	目标表/列	规则类型	严重级别	失败率	失败/总数
证件姓名=客户姓名（自然语言/专家模式）	orders.id_card_name	一致性检测	警告	22.22%	2/9
库存数量 >= 最低库存（自然语言/专家模式）	orders.quantity	多列比较	警告	11.11%	1/9
实付金额 <= 原价金额（自然语言/专家模式）	orders.paid_amount	多列比较	警告	11.11%	1/9
结束时间 >= 开始时间（手动专家模式）	orders.end_time	阈值检测	警告	11.11%	1/9
结束时间>=开始时间	orders.end_time	日期检测	严重	11.11%	1/9

3. 失败规则类型分布

失败规则主要集中在多列比较（4条）和一致性检测（2条），其次是日期与阈值检测。这表明系统在跨字段业务逻辑校验（如金额、库存、时间关联）方面存在共性短板，缺乏底层的联动约束机制。

4. 典型问题样本

- 时间倒挂：订单 ORD005 的结束时间（13:00）早于开始时间（15:00），触发严重级别日期检测。
- 金额异常：订单 ORD006 的实付金额（120.0）大于原价金额（100.0），违背基本交易逻辑。
- 身份不一致：订单 ORD004 证件姓名（赵六六）与客户姓名（赵六）不符；订单 ORD008 证件姓名为空。

5. 根因分析

问题主要源于前端录入缺乏强校验，允许了时间倒挂和超额支付等非法操作；其次，历史数据手工修改或多系统同步时未做一致性校验，导致证件与客户姓名脱节。业务规则仅停留在文档层面，未在数据库或应用层进行强制拦截。

3072 词


下载的报告为 Markdown 格式，按 5 个章节 组织：

1. 基本信息 — 报告 ID / 目标数据源 / 时间范围
2. 质量概览 — 整体评分、通过率、问题数
3. 执行明细（基于规则库） — 各规则的失败情况
4. 失败样例明细 — 具体命中行
5. 智能总结 — AI 自动分析本次质检的 失效规则详情（按失效率排序）、失效规则类型分布、典型问题样本（如时间倒挂、金额异常、身份不一致等）、根因分析（如前端录入缺乏强校验、历史数据手工修改未做一致性检查等）

十、监控中心

监控中心是系统的可观测性仪表盘，提供系统运行监控、数据分析和性能监控的全方位能力，覆盖查询量、成功率、Token 消耗、耗时与数据源健康等关键指标。

10.1 监控总览



- 本周 vs 上周：查询量、Token、平均耗时

24 小时访问热度：

折线图展示 0-23 点的查询量分布。

性能指标：

- 平均耗时
- 成功数
- 错误数
- 超时数

查询状态分布：

成功 / 错误 / 超时 三色比例。

查询质量指标：


- 平均返回卡片数
- 平均候选卡片数
- Top10 分数
- 平均结果数
- 零结果率

查询次数趋势：每日查询量柱状图

最近 7 天趋势表：


日期	查询量	成功率	Token	成本
2026-08-13	1	100%	14.2K	¥0.04
...	...	...	...	...

10.2 趋势分析



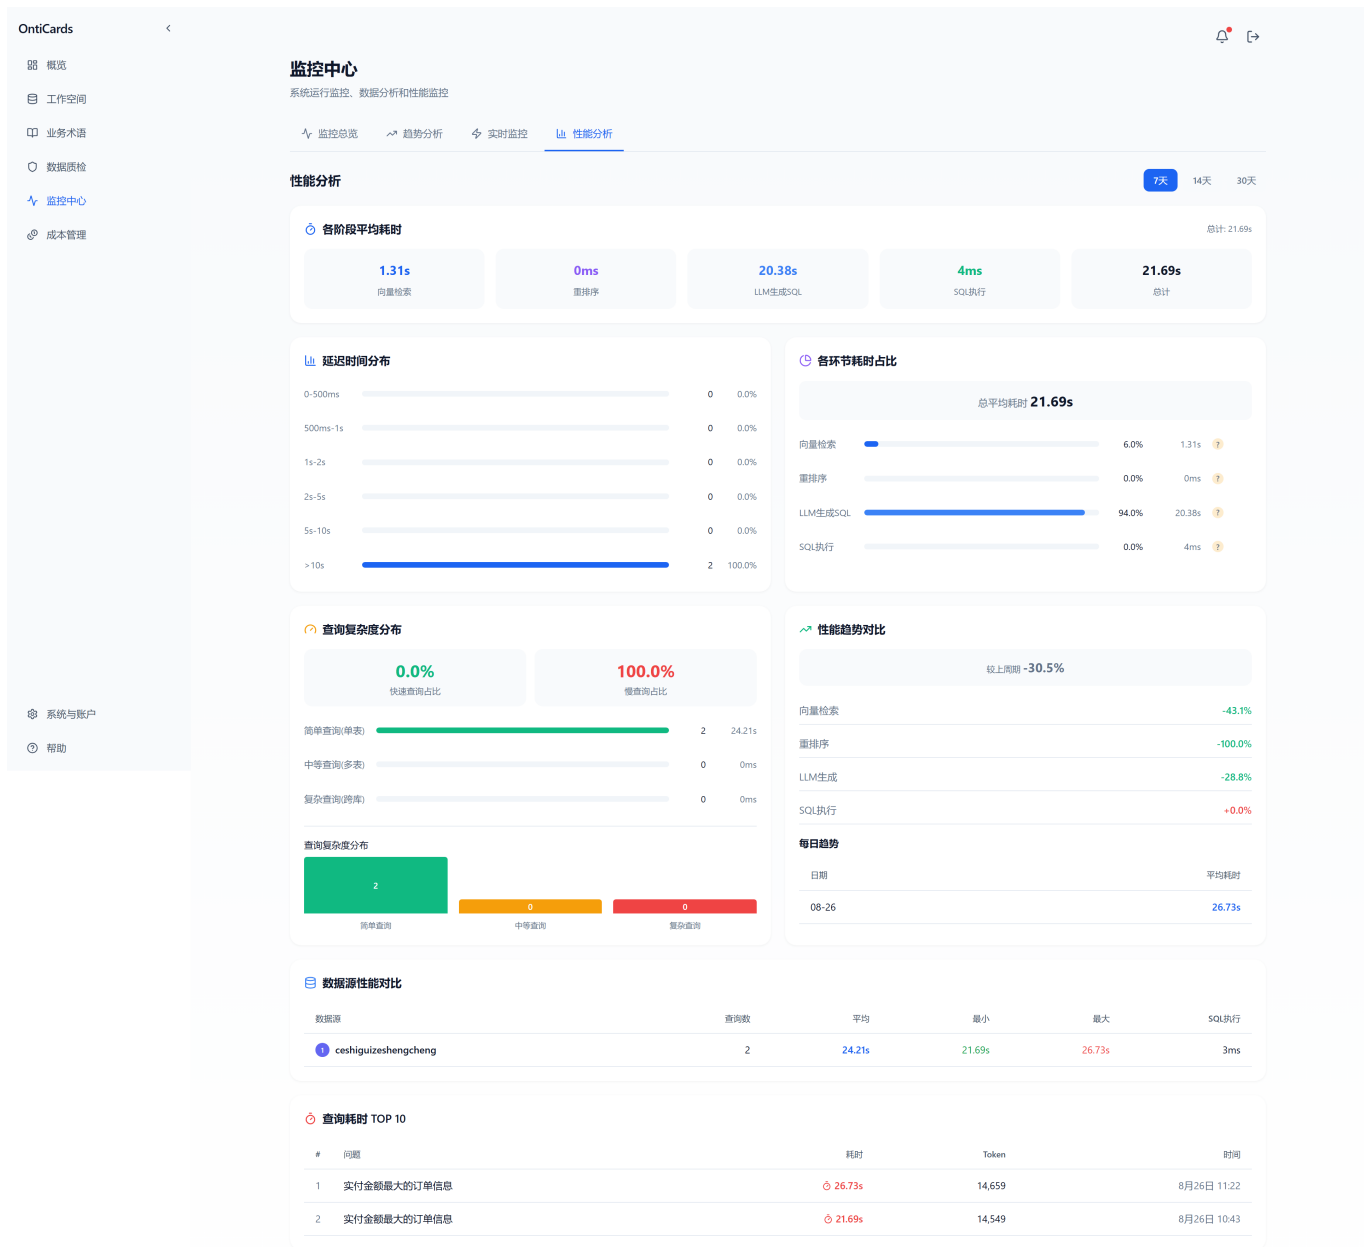
- **周/周末分布**：周一~周日每日查询量与工作日平均/周末对比
- **高峰时段 TOP 2**：统计峰值查询所在的小时段（如 10:00-11:00 / 11:00-12:00）
- **查询量趋势**：堆叠柱状图（成功 / 失败 / 超时）
- **Token 消耗趋势**：双线图（Embedding / LLM）
- **详细数据表**：含日期、查询量、成功率、Token、成本、平均耗时，支持下载 CSV

10.3 实时监控



- **顶部 3 卡**（最近 1 小时）：查询数 / 平均耗时 / Token 消耗
- **当前系统状态**：连接成功数 / 连接失败数 / 正常运行徽标
- **QPS 吞吐量监控**：当前 / 1 分钟均 / 5 分钟均 / 15 分钟均 / 峰值
- **每分钟查询量**：折线图实时滚动展示（暂无数据时显示「暂无数据」占位）
- **错误告警**：错误率、超时率（均为 0 时显示绿色「运行状态良好」提示）
- **数据源健康状态**：标记近期无数据源使用情况，建议查询以生成数据源查询请求
- **最近查询样例**：滚动展示最近 1 小时内的查询任务
- 自动刷新

10.4 性能分析



- 按时间范围（7天 / 14天 / 30天）切换
- 各阶段平均耗时卡（5卡）：向量检索、重排序、LLM生成SQL、SQL执行、总计
- 延迟时间分布：0-500ms / 500ms-1s / 1s-2s / 2s-5s / 5s-10s / >10s 共6档
- 各环节耗时占比：水平条形图展示各阶段耗时占比 + 较上周期涨跌
- 查询复杂度分布：简单查询（单表） / 中等查询（多表） / 复杂查询（跨库）占比
- 性能趋势对比：总平均耗时 vs 上周期 + 各阶段环比（向量检索 -43.1% 等）
- 每日趋势：按日展示平均耗时
- 数据源性能对比：每行的查询数、平均耗时、最小\最大耗时、SQL执行
- 查询耗时 TOP 10：列出 Top 10 慢查询（含问题、耗时、Token、时间）

十一、成本管理

「成本管理」模块提供 **Token 价格规则配置与成本统计能力**，帮助实时跟踪查询成本消耗、控制预算并优化模型使用策略。

11.1 Token 价格配置

支持为不同模型组件配置单价：

配置项	默认值	说明
Embedding 价格	0.0005 元 / 千 Token	向量检索成本
Rerank 价格	0.0008 元 / 千 Token	重排序成本
LLM 输入价格	0.0024 元 / 千 Token	SQL 生成输入
LLM 输出价格	0.0096 元 / 千 Token	SQL 生成输出

💡 实际单价以你采购的 LLM 服务为准，可在「系统与账户 → 模型配置」调整模型与对应单价。

OntiCards

<

🔍 概览

📁 工作空间

📁 业务术语

📁 数据质检

📁 监控中心

📁 成本管理

🔔

🔗

成本管理

管理Token计费规则和成本统计

🔗 Token价格

📊 成本统计

Token 价格配置

设置各类Token的单价，单位为元/千token

💾 保存配置

① 计费说明

⚠️ 提供模型服务的云厂商不同则计费规则也不同，请根据实际情况调整价格

⚠️ Token价格将用于预估计算每次查询的算力成本，修改前请确认价格单位为(元/千token)

Embedding Token

当前: 0.0005

0.0005元/千token

Embedding Token 单价 (元/千token)

LLM 输入 Token

当前: 0.0024

0.0024元/千token

LLM 输入 Token 单价 (元/千token)

Rerank Token

当前: 0.0008

0.0008元/千token

Rerank Token 单价 (元/千token)

LLM 输出 Token

当前: 0.0096

0.0096元/千token

LLM 输出 Token 单价 (元/千token)

常见 Token 价格参考 (阿里千问)

文本向量化 text-embedding-v3
0.0005 元 / 千Token

重排序 gte-rerank-v2
0.0008 元 / 千Token

普通对话 qwen-max-latest 输入
0.0024 元 / 千Token

普通对话 qwen-max-latest 输出
0.0096 元 / 千Token

🏠 系统与账户

🔗 帮助

11.2 成本统计

顶部指标卡：

- 近 30 天总成本
- 30 天总 Token
- 今日总成本
- 24 小时成本

环比变化： 查询量、Token、响应时间

查询状态分布

24 小时 Token 消耗分布：

按组件分类 (Embedding / Rerank / LLM)

每日成本趋势 (近 7 天)：


横向条形图展示每日成本，右侧显示占比与金额。


24 小时查询分布：

24 小时查询量分布柱状图 (按 30 分钟粒度)

数据源使用统计：

每个数据源消耗的 Token 与成本占比。






设置中心包含 7 个子模块：

Tab	用途
账户	个人基本信息、修改密码
用户管理	管理系统用户（仅管理员可见）
API 密钥	管理第三方调用的 API Key
模型配置	配置 AI 模型（基础对话、向量化、重排序）
数据保密	敏感字段脱敏配置
鉴权日志	登录与操作审计日志
系统设置	系统级配置

12.1 账户信息



- 头像、昵称
- 邮箱（用于找回密码）
- 修改密码
- 「保存修改」提交

12.2 用户管理

OntiCards

概览

工作空间

业务术语

数据质检

监控中心

成本管理

系统与客户

帮助

设置

管理您的账户和系统配置

账户用户管理API密钥模型配置数据保留更新日志系统设置

用户管理

管理系统用户和权限

+ 添加用户

搜索用户名、昵称或邮箱...

用户名	昵称	角色	状态	最后登录	操作
ttrial_df	trial_df	普通用户	正常	2025/11/28 14:46:10	
高trial_gyhw	高阳测试用户	普通用户	正常	2025/12/02 09:37:24	
别trial_gy123@qq.com	测试用户_gy	普通用户	正常	2025/11/19 16:39:36	
ttrial_md	trial_md	普通用户	正常	2025/12/12 18:43:43	
火volcenginevolcengine_test@qq.com	火山测试用户	普通用户	正常	2026/02/04 15:21:31	
上trial_shanghaitrial_shanghai@qq.com	上海合作商测试用户	普通用户	正常	2026/02/10 10:55:47	
ttrial_marktrial_mark@qq.com	trial_mark	普通用户	正常	2026/01/12 17:56:34	
四trial_sichuan	四川银行测试用户-单数据源	普通用户	正常	2026/02/03 09:56:05	
xxiaohe	xiaohe	管理员	正常	2026/06/25 14:36:36	
南trial_nw	南网测试	普通用户	正常	2026/05/13 14:55:16	

共 41 条记录，第 1 / 5 页

首页< 上一页12345下一页末页

每页显示10条

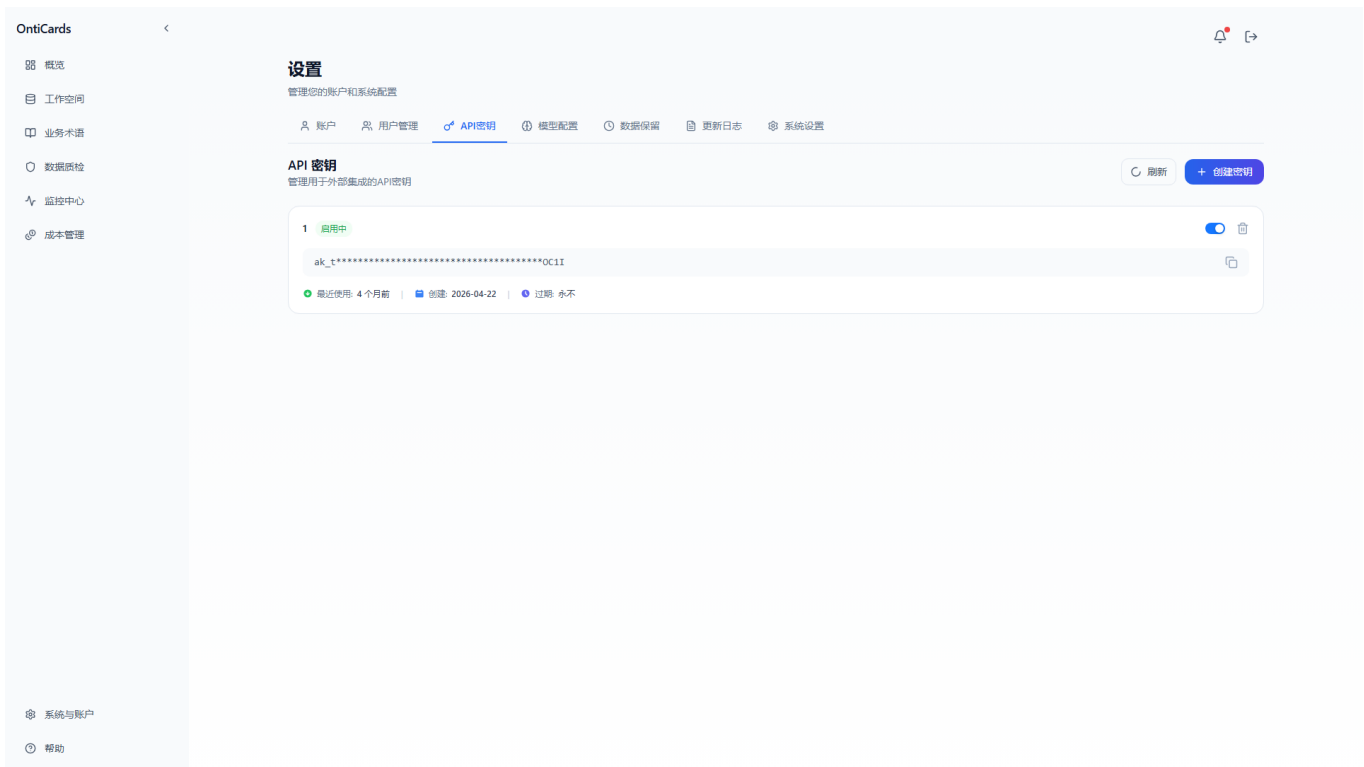
仅管理员可见。提供：

- 用户列表：用户名、昵称、角色、状态、最后登录时间
- 搜索：按用户名、昵称、邮箱
- 添加用户：右上角「添加用户」按钮
- 编辑用户：每行末尾的「编辑」图标
- 删除用户：每行末尾的「删除」图标
- 分页：共 N 条记录，可翻页

角色包括：

- **管理员**：拥有所有权限
- **普通用户**：受限的功能访问

12.3 API 密钥



用于第三方系统集成。提供：

- API 密钥列表
- 状态显示（启用 / 停用）
- 「创建密钥」生成新的 API Key
- 复制密钥值
- 启用/停用、删除密钥

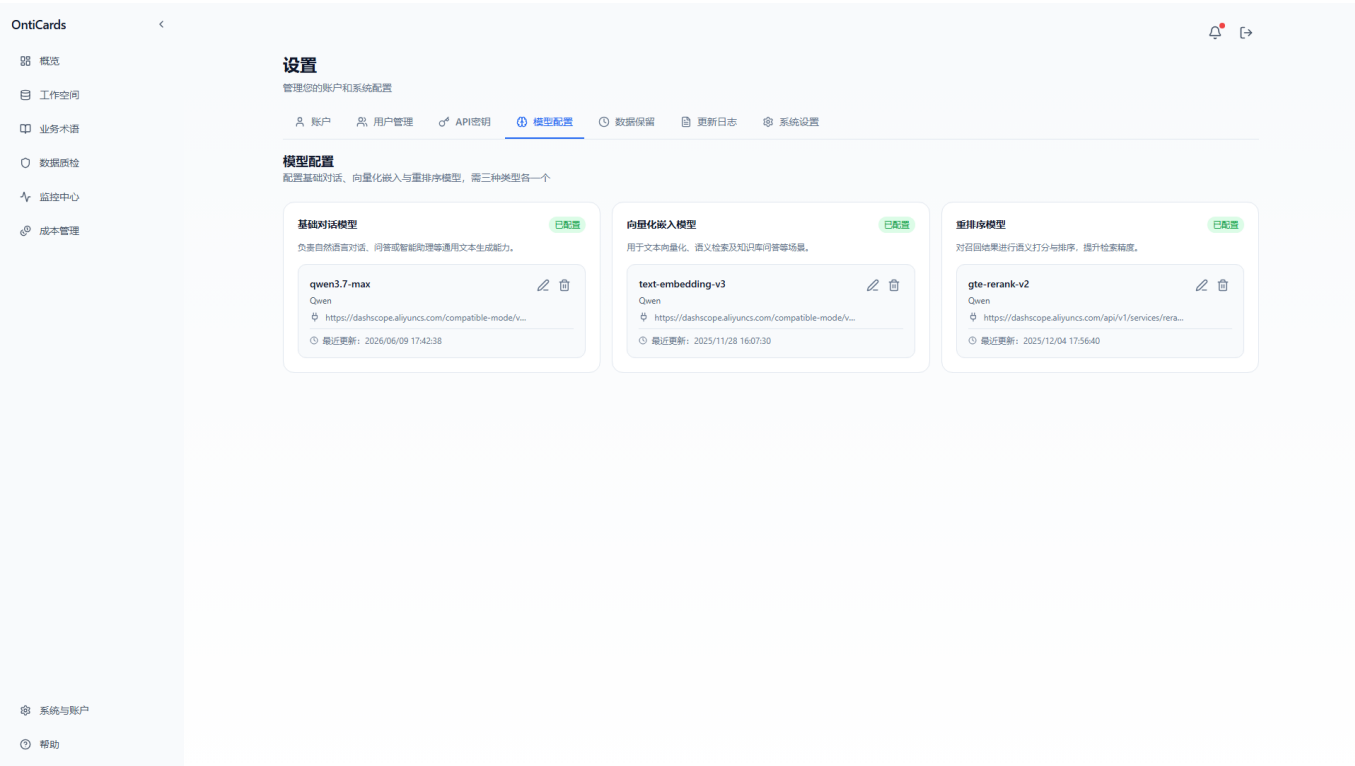
使用方式：

```
curl -X POST https://your-host/api/v1/query \  
-H "Authorization: Bearer ak_XXXXXXXXXXXX" \  
-H "Content-Type: application/json" \  
-d '{  
  "question": "查询最近 7 天的订单量",  
  "data_source_id": 1  
}'
```

 **安全提示：**请妥善保管 API 密钥，定期轮换。如发现泄露，立即停用并重新创建。

详细接口文档：[API 接口文档](#)

12.4 模型配置



OntiCards 依赖 3 类 AI 模型：

模型类型	作用	配置字段
基础对话模型	负责自然语言理解、SQL 生成	名称、API 兼容地址、API Key
向量化模型	把文本转为向量用于检索	名称、API 兼容地址、API Key
重排序模型	优化检索结果排序	名称、API 兼容地址、API Key

配置步骤：

1. 选择模型类型卡片
2. 填写：
 - 名称（如 qwen3.7-max）
 - 兼容 OpenAI 的 API 地址（如 https://dashscope.aliyuncs.com/compatible-mode/v1）
 - API Key
3. 测试连接
4. 启用

✔ 系统支持 任意 OpenAI 兼容接口，可对接阿里云通义、DeepSeek、OpenAI、Azure OpenAI、Anthropic 等。

12.5 数据保密

用于配置 **敏感字段脱敏**：

- 选择数据源
- 选择需要脱敏的字段
- 选择脱敏策略（部分掩码、哈希、置空）
- 应用到问数结果展示

脱敏后的字段：

- 在查询结果中按规则展示
- 在导出文件中按规则展示
- 不影响原始数据库


12.6 鉴权日志

记录所有用户操作：

- 登录 / 登出
- 数据源新增 / 修改 / 删除
- 规则新增 / 执行
- API 调用
- 敏感操作

每条记录包含：用户、时间、IP、操作类型、对象、结果。

12.7 系统设置



系统级配置：

- 默认主题（浅色 / 深色）

十三、数据安全

OntiCards 在多个层面保障数据安全：

13.1 访问隔离

- 用户与数据源是 **多对一** 关系
- 每位用户只能访问自己添加的数据源
- 不同用户之间的数据源互相不可见
- 工作空间与术语库按用户隔离

13.2 只读保护

- 系统 **只执行** SELECT (查询) 操作
- **不提供** 任何 INSERT / UPDATE / DELETE / DROP / ALTER 的入口
- 所有生成的 SQL 都经过安全校验
- 危险关键词 (如 DROP、TRUNCATE) 被强制过滤

13.3 密码保护

- 数据库密码使用加密算法 (AES-256) 存储
- 密码 **不会** 出现在界面、查询结果、日志中
- 密码在传输过程中通过 HTTPS 加密
- 切换数据源时密码自动遮罩显示

13.4 操作审计

- 所有用户的关键操作被记录
- 包含: 时间、用户、IP、操作类型、对象、结果
- 审计日志不可篡改 (只追加)
- 支持导出与第三方 SIEM 对接

13.5 敏感脱敏

- 字段级脱敏策略
- 问数结果按策略脱敏
- API 返回结果按策略脱敏
- 不影响原始数据存储

13.6 SSO 与 MFA

- 支持 JWT Token 模式 SSO
- 可对接企业级身份系统 (LDAP、AD、OAuth2.0、OIDC、CAS)
- 可启用多因素认证 (MFA)



JWT 模式 SSO 的完整对接流程见 [第十五章 SSO 单点登录对接 \(JWT 模式\)](#)。

十四、API 与第三方集成

OntiCards 通过 REST API 暴露核心能力，支持与以下系统集成：

- **AI 智能体 / Agent**：把"自然语言问数"能力嵌入到 AI Agent
- **RPA / 自动化平台**：定时自动问数并推送结果
- **BI 平台**：作为 BI 的「智能问数」增强层
- **企业微信 / 钉钉 / 飞书机器人**：让用户在 IM 中直接问数据
- **自研业务系统**：把"问数据"能力嵌入到业务后台

14.1 鉴权方式

使用 API Key 进行鉴权：

```
Authorization: Bearer ak_XXXXXXXXXXXXXXXXX
```

14.2 核心接口

接口	方法	用途
/api/v1/query	POST	提交自然语言问题
/api/v1/query/{id}	GET	查询执行结果
/api/v1/datasources	GET	列出数据源
/api/v1/terms	GET	列出业务术语
/api/v1/health	GET	健康检查

示例：自然语言问数

```
curl -X POST https://your-host/api/v1/query \
-H "Authorization: Bearer ak_XXXXXXX" \
-H "Content-Type: application/json" \
-d '{
  "question": "查询最近 30 天的订单量",
  "data_source_id": 1
}'
```

响应：

```
{
  "query_id": "q_abc123",
  "status": "success",
  "sql": "SELECT DATE(created_at) AS day, COUNT(*) FROM orders WHERE created_at >= NOW() - INTERVAL 30 DAY GROUP BY day",
  "data": [
    {"day": "2026-07-27", "count": 1234},
    {"day": "2026-07-28", "count": 1456}
  ],
  "duration_ms": 412,
  "tokens": 1432
}
```

详细 API 文档: [API 接口文档](#)

14.3 Webhook

支持配置 Webhook, 在以下事件触发时推送通知:

- 查询完成
- 质检报告生成
- 数据源异常

十五、SSO 单点登录对接 (JWT 模式)

当企业已有自己的用户体系 (门户、OA、业务系统) 时, 可通过 **JWT 模式 SSO 单点登录** 与 OntiCards 打通用户体系: 用户在己方系统完成登录后, 无需二次输入账号密码, 即可直接跳转进入 OntiCards。

 本章面向负责对接的**开发人员**。SSO 配置完成后, 终端用户的登录体验与普通登录一致。

15.1 什么是 JWT Token

JWT (JSON Web Token) 是一种开放标准 (RFC 7519), 用于在各方之间安全地传输信息。JWT 由三部分组成, 用点号分隔:

```
eyJhbGciOiJIUzI1NiIsInR5cCI6IkpXVCJ9.eyJ1c2VybWVtZSI6InpoYW5nX3NhbiIsInVzZXJfYWQiOiJTWVNFVVNFU18wMDEifQ.signature
```

Header	Payload	Signature
头部	用户数据	签名

部分	名称	作用	示例内容
第一部分	Header（头部）	声明算法和类型	<code>{"alg": "HS256", "typ": "JWT"}</code>
第二部分	Payload（负载）	存放实际的用户数据	<code>{"username": "zhang_san", "user_id": "001", ...}</code>
第三部分	Signature（签名）	用密钥对前两部分签名，确保不被篡改	<code>Sf1KxwRJSMeKKF2QT4fwpMeJf36P0k6yJV_adQssw5c</code>

15.2 整体流程

1. 客户后端生成 JWT Token

↓

2. 拼接 SSO 登录 URL（带上 token 和 redirect_url）

↓

3. 用户浏览器跳转到 OntiCards 的 SSO 接口

↓

4. OntiCards 验证 JWT、创建/关联用户、生成自己的 Token

↓

5. 浏览器跳转到 redirect_url，带上 OntiCards 的 Token

↓

6. 客户前端接收 Token，登录完成

 **用户自动关联：**首次通过 SSO 访问时，OntiCards 会根据 user_id + source 查找已存在用户；新用户自动创建，老用户直接关联登录，无需人工开通账号。

15.3 配置清单

对接前需要准备以下配置：

配置项	说明	示例值
SSO 共享密钥	用于 JWT 签名，两端必须一致	K7x#9mP\$2nL5@qR8（建议 64 位以上随机字符串）
OntiCards API 地址	OntiCards 的 SSO 登录接口地址	https://api.onticards.com
回调跳转地址	登录成功后跳转的前端页面	https://frontend.onticards.com/overview

服务端配置：在 OntiCards 服务端 .env 中配置共享密钥（详见[部署指南](#)）：

SSO_SECRET_KEY=客户提供的共享密钥

15.4 Token 生成详解

Token 生成**必须由客户后端完成**（共享密钥不能暴露在前端）。

① **Header（头部）**：固定格式，声明使用 HS256 算法，然后进行 Base64URL 编码：

```
{
  "alg": "HS256",
  "typ": "JWT"
}
```

② **Payload（负载/用户数据）**：包含要传递的用户信息：

字段	类型	必填	说明
username	string	✓	用户的唯一标识，不能为空
user_id	string	✓	客户系统中的用户 ID，不能为空
nickname	string	✗	用户昵称
email	string	✗	用户邮箱
source	string	✗	来源标识，用于区分不同系统，默认 default
iat	number	✗	Token 签发时间（Unix 时间戳）
exp	number	✓	Token 过期时间（Unix 时间戳），建议设置为 5 分钟后

③ **Signature（签名）**：将前两部分用点号连接后，用共享密钥签名：

```
签名字符串 = Header_base64 + "." + Payload_base64
签名 = HMAC-SHA256(签名字符串, 共享密钥)
```

最终的 JWT Token：

```
JWT Token = Header_base64 + "." + Payload_base64 + "." + Signature_base64
```

15.5 各语言示例

Python：

```
import jwt
from datetime import datetime, timedelta, timezone

SECRET_KEY = "your_shared_secret_key" # 与 Onticards 服务端共享的密钥

payload = {
```



```

    "username": "zhang_san",
    "user_id": "SYS_USER_001",
    "nickname": "张三",
    "email": "zhangsan@example.com",
    "source": "your_app",
    "iat": datetime.now(timezone.utc),
    "exp": datetime.now(timezone.utc) + timedelta(minutes=5) # 5 分钟后过期
}

token = jwt.encode(payload, SECRET_KEY, algorithm="HS256")
print(token)

```

Java (jjwt 0.12+) :

```

String token = Jwts.builder()
    .claims(Map.of(
        "username", "zhang_san",
        "user_id", "SYS_USER_001",
        "nickname", "张三",
        "email", "zhangsan@example.com",
        "source", "your_app"))
    .issuedAt(new Date())
    .expiration(new Date(System.currentTimeMillis() + 5 * 60 * 1000))
    .signWith(Keys.hmacShaKeyFor(secretKey.getBytes(StandardCharsets.UTF_8)))
    .compact();

```

Node.js:

```

const jwt = require('jsonwebtoken');

const token = jwt.sign({
  username: 'zhang_san',
  user_id: 'SYS_USER_001',
  nickname: '张三',
  email: 'zhangsan@example.com',
  source: 'your_app'
}, 'your_shared_secret_key', {
  algorithm: 'HS256',
  expiresIn: '5m' // 5 分钟后过期
});

```

⚠ 生产环境 Token 生成**必须**在**后端完成**，共享密钥绝不能出现在前端代码中。

15.6 拼接登录 URL 并跳转

构造 URL：

```
{OntiCards API地址}/sso/login?token={JWT Token}&redirect_url={回调地址}
```

示例：

```
https://api.onticards.com/sso/login?token=eyJhbGciOiJIUzI1NiIsInR5cCI6IkpXVCJ9...&redirect_url=https://frontend.onticards.com/overview
```

跳转代码（生成 Token 后执行跳转，推荐直接跳转）：

```
const ssoUrl = `${API_BASE}/sso/login?token=${encodeURIComponent(token)}&redirect_url=${encodeURIComponent(FRONTEND_URL)}`;
window.location.href = ssoUrl;
```

15.7 回调接收 Token

登录成功后，浏览器会跳转到：

```
https://frontend.onticards.com/overview?access_token=eyJhbGciOiJIUzI1NiIsInR5cCI6IkpXVCJ9...
```

前端接收 Token 的代码：

```
// 从 URL 获取 access_token 参数
function getAccessToken() {
  return new URLSearchParams(window.location.search).get('access_token');
}

const token = getAccessToken();
if (token) {
  localStorage.setItem('access_token', token);
  // 清理 URL 中的 token 参数（防止 token 泄露）
  window.history.replaceState({}, document.title, window.location.pathname);
}

// 后续 API 请求时在 Header 中携带 Token
fetch('/api/your-endpoint', {
  headers: { 'Authorization': 'Bearer ' + localStorage.getItem('access_token') }
});
```

15.8 错误码说明

HTTP 状态码	error 字段	原因
400	缺少token参数	URL 中没有传 token
400	token中缺少必要的用户信息	Payload 中 username 或 user_id 为空
401	token已过期	Token 的 exp 已过期
401	token无效	签名验证失败（密钥不匹配或内容被篡改）

15.9 测试验证

本地测试页面：

- **SSO 测试中心：** http://localhost:9000/static/sso_test.html
- **回调测试页面：** http://localhost:9000/static/sso_callback.html

对接检查清单：

- ✓ 生成 JWT Token（验证三部分结构：Header.Payload.Signature）
- ✓ Payload 中包含必填字段：username、user_id、exp
- ✓ Token 使用 HS256 算法签名
- ✓ 拼接 SSO 登录 URL 并测试跳转流程
- ✓ 验证回调页面能接收 access_token
- ✓ 确认 Token 有效期（建议 5 分钟）
- ✓ 生产环境使用强密钥，不要使用示例密钥

十六、常见问题（FAQ）

Q1：登录后看不到数据源？

原因：

- 你是新用户，还没有添加过数据源
- 或管理员还未授权

解决：

- 在「工作空间」点击「添加新数据源」
- 或联系管理员授权

Q2：数据卡片生成很慢？

原因：

- 数据源表数量大
- 字段数多
- LLM 响应慢

建议：

- 等待系统异步完成（可在「任务」Tab 查看进度）
- 调整 LLM 基础对话模型为更快的模型
- 大表可分批刷新

Q3：问数结果不准？

按以下顺序排查：

1. **数据卡片质量**：表与字段的描述是否准确
2. **业务术语库**：是否定义了你问题中的业务概念
3. **数据盘点**：表之间的关系是否已盘点
4. **提问方式**：是否表达得足够具体
5. **查看「查询说明」**：系统如何理解你的问题

Q4：部分条件被忽略？

系统在解析时无法在当前数据库中识别某些条件。会：

- 执行能识别的条件
- 在结果中明确标注「被忽略的条件」及原因
- 提示你如何补充（如增加数据卡片）

Q5：查询速度慢？

建议：

- 增加时间范围限制
- 加上必要的筛选条件
- 避免一次性查询过多数据

- 联系 DBA 优化相关表索引

Q6: Token 消耗大?

建议:

- 简化问题描述
- 减少不必要的历史对话
- 切换到更小更快的模型
- 在「系统与账户 → 模型配置」中调整

Q7: API Key 泄露了怎么办?

立即处理:

1. 在「API 密钥」中**停用**该密钥
2. 创建新密钥
3. 更新所有使用方
4. 检查「鉴权日志」看是否有异常调用

Q8: 想增加新数据库类型?

- 开源版支持的数据库见 [§3.3](#)
- 商业版可定制更多数据库
- 提交 [Feature Request](#)

十七、获取帮助

文档

文档	链接
快速开始	快速开始.md
部署指南	部署指南.md

文档	链接
API 接口文档	API接口文档.md
FAQ	FAQ.md
问题排查	问题排查指南.md
更新日志	CHANGELOG.md

在线资源

- **GitHub Issues**: 提交 Bug 或功能请求
- **产品官网**: <https://onticards.example.com>
- **技术博客**: <https://onticards.example.com/blog>
- **社区论坛**: 扫码加入用户交流群

商业支持

需要企业级支持、定制开发、私有化部署、行列级权限、SSO 增强等高级能力，请联系商业团队。

 **下一步**: [快速开始](#) · [API 接口文档](#) · [问题排查指南](#)

本文档最后更新时间: 2026 年 8 月